

UNIVERSIDAD POLITÉCNICA DE MADRID
Escuela Técnica Superior de Ingeniería de Sistemas Informáticos



**Análisis Inteligente del Mercado
Inmobiliario en Madrid: Diseño de un
Cuadro de Mando Basado en Datos
Abiertos**

PROYECTO FIN DE GRADO

Rodrigo Alonzo Peña Vigil
Grado en Ingeniería del Software

Madrid, 2025



UNIVERSIDAD POLITÉCNICA DE
MADRID
Escuela Técnica Superior de Ingeniería de
Sistemas Informáticos

Grado en Ingeniería de Software

Análisis Inteligente del Mercado Inmobiliario en Madrid: Diseño de un Cuadro de Mando Basado en Datos Abiertos

PROYECTO FIN DE GRADO

Rodrigo Alonzo Peña Vigil

Grado en Ingeniería del Software

Bajo la tutoría de:

Dr. Pedro Pablo Alarcón Caveró

Madrid, 2025

Trabajo Fin de Grado

Grado en Ingeniería del Software

Título: Análisis Inteligente del Mercado Inmobiliario en Madrid: Diseño de un
Cuadro de Mando Predictivo Basado en Datos Abiertos

Junio 2025

Autor: Rodrigo Alonzo Peña Vigil

Tutor:

Dr. Pedro Pablo Alarcón Caveró

Departamento Sistemas Informáticos

ETSI informáticos

Universidad Politécnica de Madrid

Dedicatoria

A mis padres, por su amor inagotable, su apoyo constante y por enseñarme cada día el valor del esfuerzo.

A mi hermana, por ser siempre un recordatorio de alegría y por animarme a seguir adelante, incluso en los momentos difíciles.

Y a mí mismo, por seguir de pie y no rendirme.

Agradecimientos

Quiero agradecer, en primer lugar, a mi tutor Pedro Pablo Alarcón Cavero, por su guía clara, disponibilidad constante y valiosas sugerencias a lo largo del desarrollo de este trabajo.

A mis padres, por su apoyo incondicional en cada etapa de mi formación. Gracias por confiar en mí incluso cuando yo dudaba.

Además, quiero expresar mi agradecimiento a mis amigos y compañeros de carrera, por compartir ideas, momentos de estrés y risas, y por hacer este camino más llevadero.

Este trabajo no habría sido posible sin su ayuda y dedicación, y estoy muy agradecido por ello.

Resumen

En un mercado inmobiliario tan dinámico y complejo, especialmente en grandes ciudades como Madrid, tomar decisiones apropiadas sobre comprar o alquilar vivienda se convierte en un reto. A menudo, los ciudadanos carecen de herramientas accesibles y comprensibles que les permitan interpretar los datos disponibles y anticipar tendencias. Este Trabajo de Fin de Grado responde a esa necesidad mediante el diseño y desarrollo de una solución tecnológica que convierte datos públicos en conocimiento útil, accesible y visual.

El objetivo del proyecto radica en el desarrollo de un cuadro de mando interactivo orientado a datos abiertos, que ayude a estimar los precios de venta y alquiler, visualizar la evolución del mercado y comparar zonas de Madrid de forma intuitiva. La motivación personal viene de la mano de aplicar conocimientos de ingeniería del software a un problema práctico con impacto social, mientras que la colectiva se enfoca en demostrar el poder de los datos abiertos para empoderar a los ciudadanos.

El proyecto consiste en una plataforma analítica basada en un DataMart relacional, un proceso ETL desarrollado con KNIME y un cuadro de mando interactivo creado con Power BI. Utiliza datos abiertos de múltiples fuentes para ofrecer visualizaciones dinámicas, modelos de estimación y filtros avanzados por distrito y barrio. Los usuarios pueden consultar precios medios, rentabilidades, evolución temporal y comparar zonas de forma intuitiva, sin necesidad de conocimientos técnicos.

El resultado es una herramienta funcional, clara y potente, que transforma grandes volúmenes de datos en visualizaciones útiles para tomar decisiones más informadas, seguras y rápidas. La interfaz prioriza la experiencia de usuario mediante un diseño visual limpio y medidas DAX personalizadas que mejoran el análisis.

Este TFG demuestra cómo la ingeniería del software puede transformar datos complejos en soluciones reales con impacto social. La plataforma desarrollada es funcional, robusta y escalable, y establece una base sólida para futuras mejoras como el uso de datos en tiempo real, más variables macroeconómicas o la expansión geográfica de la herramienta.

Abstract

In a real estate market as dynamic and complex as that of major cities like Madrid, making informed decisions about buying or renting a home becomes a significant challenge. Citizens often lack accessible and understandable tools to interpret available data and anticipate market trends. This Bachelor's Thesis addresses that gap through the design and development of a technological solution that transforms public data into useful, accessible, and visual knowledge.

The main goal of the project is the development of an interactive dashboard based on open data, aimed at estimating sale and rental prices, visualizing market trends, and comparing areas of Madrid in an intuitive way. The personal motivation behind the project lies in applying software engineering skills to a real-world problem with social impact, while the collective motivation focuses on showcasing the power of open data to empower citizens.

The project consists of an analytical platform built on a relational DataMart, an ETL process developed with KNIME, and an interactive dashboard created with Power BI. It leverages open data from multiple sources to provide dynamic visualizations, estimation models, and advanced filtering by district and neighborhood. Users can explore average prices, profitability, historical trends, and compare different zones without requiring technical knowledge.

The result is a functional, clear, and powerful tool that turns large volumes of data into meaningful visualizations, helping users make faster, safer, and more informed decisions. The interface prioritizes user experience through a clean visual design and customized DAX measures that enhance analytical depth.

This thesis demonstrates how software engineering can turn complex data into real solutions with social relevance. The platform is robust, scalable, and lays a solid foundation for future enhancements such as real-time data integration, the inclusion of macroeconomic variables, or geographical expansion.

Tabla de Contenidos

1. Introducción	1
2. Estado del Arte	3
2.1. Fuente de los datos	3
2.1.1. Portal Inmobiliario	3
2.1.2. Portal de Datos Abiertos del Ayuntamiento de Madrid	4
2.1.3. INE y Datos abiertos del Gobierno de España	5
2.2. Herramientas de visualización de datos	7
2.3. Herramienta de ETL	8
2.4. Herramientas de almacenamiento de datos	13
3. Datos de Partida	16
3.1 Descripción general de las fuentes de datos	16
3.1.1 Distritos de Madrid	16
3.1.2 Barrios de Madrid	17
3.1.3 Evolución de Precios	18
3.1.4. Datos Económicos	20
3.2 Características generales y procesos de preparación inicial	21
4. Diseño del Datamart	23
4.1. Introducción al Modelo en Estrella del DataMart	23
4.2. Descripción de las Dimensiones	25
4.2.1. Dimension Tiempo	25
4.2.2. Dimensión Distrito	26
4.2.3. Dimensión Barrio	26
4.3. Descripción de las Tablas de Hechos	27
4.3.1. Hechos de Operación	27
4.3.2. Hechos económicos	29
4.4. Integridad Referencial y Claves	30
4.5. Diagrama Relacional y Topología en Estrella	32

5. Proceso de ETL.....	34
5.1 Introducción general al proceso ETL	34
5.2 Extracción de datos (Extract).....	34
5.3 Transformación de datos (Transform)	34
5.3.1 ETL para dim_distrito	35
5.3.2. ETL para dim_barrio	40
5.3.3. ETL para Fact_Operacion	43
5.3.4. ETL para Fact_Economico.....	51
6. Capa de presentación.....	55
6.1. Diseño general del cuadro de mando	55
6.1.1. Área Superior: Filtros de Segmentación.....	55
6.1.2. Zona Central: Indicadores Clave y Visualizaciones Destacadas	56
6.1.3. Zona Inferior: Gráficas Analíticas Detalladas.....	57
6.1.4. Coherencia Visual y Guía del Usuario.....	57
6.2. Filtros disponibles	58
6.2.1. Año y Mes	58
6.2.2. Tipo de Operación:	58
6.2.3. Distrito y Barrio:.....	58
6.2.4. Aplicación Dinámica:	59
6.3. Visualizaciones y su propósito	60
6.4. Ayudas contextuales para el usuario.....	62
6.5. Experiencia de usuario (UX)	63
6.5.1. Diseño Limpio y Claro	63
6.5.2. Uso Coherente y Semántico del Color	63
6.5.3. Navegación Clara e Intuitiva	64
6.5.4. Facilitación de la Toma de Decisiones	64
6.6. Uso de medidas personalizadas en Power BI.....	64
6.6.1. Racionalidad para el Uso de Medidas Personalizadas	65
6.6.2. Ventajas del Enfoque de Medidas Personalizadas	66

7. Resultados	68
7.1. Logros Fundamentales del Cuadro de Mando	68
7.2. Capacidades Funcionales y Experiencia del Usuario Final	71
7.3. Información Clave y Análisis Derivables	74
7.4. Contribución a la Toma de Decisiones Basadas en Datos	77
7.5. Valor Práctico y Operatividad del Dashboard	78
7.6. Funcionalidad adicional: Calculadora de rentabilidad (versión beta)	79
8. Impacto Socioambiental	88
8.1. Naturaleza del Proyecto y su Impacto Ambiental Directo	88
8.2. Consumo de recursos del software utilizado	88
8.3. Uso de Hardware e Infraestructura	89
8.4. Sostenibilidad Digital	89
8.5. Contribución Indirecta a Modelos Urbanos Sostenibles	90
9. Conclusiones	91
9.1. Revisión de las Aportaciones del Trabajo	91
9.2. Aprendizajes Clave e Hitos del Desarrollo	91
9.3. Vías de Continuación	92
9.4. Reflexión Final Personal	92
10. Referencias	94
11. Anexos	96

Índice de ilustraciones

Ilustración 1 - Sección de informes de precios de vivienda publicada por Idealista	4
Ilustración 2 - Sección "Mercado de la vivienda" del portal estadístico del Ayuntamiento de Madrid.....	5
Ilustración 3 - Página del Instituto Nacional de Estadística (INE) sobre el Índice de Precios de Vivienda (IPV)	6
Ilustración 4 - Panel de indicadores de distritos y barrios de Madrid – Datos abiertos del Gobierno de España	7
Ilustración 5 - Página principal del sitio oficial de KNIME.....	12
Ilustración 6 - MySQL Workbench 8.0 CE (Community Edition).....	15
Ilustración 7 - Dimensión de Tiempo	25
Ilustración 8 - Dimensión de Distrito.....	26
Ilustración 9 - Dimensión Barrio.....	27
Ilustración 10 - Hechos de Operación.....	29
Ilustración 11 - Hechos Económicos	30
Ilustración 12 - DataMart Mercado Inmobiliario	33
Ilustración 13 - Superficie media (m2) de las viviendas por Tipo, Distrito y Barrio	35
Ilustración 14 - Nodo Excel Reader.....	35
Ilustración 15 - Nodo Column Renamer.....	36
Ilustración 16 - Nodos String Manipulation	36
Ilustración 17 - Asignación de datos útiles de distritos.....	36
Ilustración 18 - Set de datos de Distritos.....	37
Ilustración 19 - Nodo Joiner	37
Ilustración 20 - Unión por Código de distrito	37
Ilustración 21 - Obtenemos la fila coincidente.....	38
Ilustración 22 - Datos incluidos y excluidos.....	38
Ilustración 23 - Nodo MySql Connector	38
Ilustración 24 - Nodo Credentials Widget.....	38
Ilustración 25 - Nodo Insert.....	39
Ilustración 26 - Configuración del Nodo Insert para Dim_Distrito	39
Ilustración 27 - ETL Dim_Distrito	39
Ilustración 28 - Separación del código de la zona	40
Ilustración 29 - Set de datos de Barrios	41
Ilustración 30 - Configuración del nodo Joinner.....	41

Ilustración 31 - Nodo DB Query Reader	41
Ilustración 32 - Configuración del Nodo Insert para Dim_Barrio	42
Ilustración 33 - ETL Dim_Barrio	42
Ilustración 34 - Set de datos Evolución del precio de alquiler de la vivienda (€/m2) por Distrito y Barrio.....	43
Ilustración 35 - Configuración del nodo CSV Reader	43
Ilustración 36 - Nodo Unpivot	44
Ilustración 37 - Configuración del nodo Unpivot.....	44
Ilustración 38 - Nodo Rule Engine	44
Ilustración 39 - configuración del nodo String Manipulation para el código de los distritos.....	45
Ilustración 40- configuración del nodo String Manipulation para el código de tiempo	45
Ilustración 41 - Configuración del nodo Column Filter.....	46
Ilustración 42 - configuración del nodo Row Filter.....	46
Ilustración 43 - Nodo String to Number	46
Ilustración 44 - Nodo Constant Value Column.....	47
Ilustración 45 - Configuración del nodo Constant Value Column	47
Ilustración 46 - Consulta para añadir el nuevo valor “000”	47
Ilustración 47 - Nodo Python Script.....	47
Ilustración 48 - Configuración de Python Script para obtener las variaciones temporales	48
Ilustración 49 - Configuración de Python Script para obtener las medidas restantes	49
Ilustración 50 - Conjunto de datos de Evolución del precio de venta de la vivienda (€/m2) por Distrito y Barrio	50
Ilustración 51 - Nodo Concatenate	50
Ilustración 52 - Nodo Column Expressions.....	50
Ilustración 53 - Configuración del Nodo Column Expressions.....	51
Ilustración 54 - ETL de Fact Operación.....	51
Ilustración 55 - Nodo Pivot	52
Ilustración 56 - Configuración del nodo Pivot.....	52
Ilustración 57 - Nodo Transposer	52
Ilustración 58 - Nodo RowID	53
Ilustración 59 - ETL Fact Economico	54
Ilustración 60 - Zona Central del cuadro de mando	56
Ilustración 61 - Zona Inferior del cuadro de mando	57

Ilustración 62 - Zona de Comparación de precios por distritos o barrios	59
Ilustración 63 - Funcionamiento del botón informativo	63
Ilustración 64 - Cuadro de mando Insight Madrid	69
Ilustración 65 - Gráfico de rentabilidad y volatilidad con tooltip explicativo visible	70
Ilustración 66 - Filtros activos y medidas recalculadas del mes de Julio del año 2024	71
Ilustración 67- Filtros activos y medidas recalculadas del mes de Noviembre del año 2024.....	71
Ilustración 68 - Alquiler, año 2023, distrito Centro	72
Ilustración 69 - Comparativa de 2 distritos (ej. Salamanca vs Usera)	73
Ilustración 70 - Gráfico tipo barra con Top 5 distritos más caros/baratos	74
Ilustración 71 - Gráfico de evolución mensual del precio por m ² 2024	75
Ilustración 72 - Mapa de calor temporal 2024	75
Ilustración 73 - Gráfico de dispersión: rentabilidad vs volatilidad 2024.....	76
Ilustración 74 - Calculadora de Rentabilidad (versión beta)	87
Ilustración 75 - Script para obtener las variaciones temporales	96
Ilustración 76 - Script para obtener las medidas restantes; Error! Marcador no definido.	
Ilustración 77 - Medida Dax _Top5VentaBarriosMasBaratos	98
Ilustración 78 - Medida Dax _Top5VentaDistritosMasCaros	98
Ilustración 79 - Medida Dax _RentabilidadBruta	98
Ilustración 80 - Medida Dax _PrecioMedioVenta	98
Ilustración 81 - Medida Dax _VolatilidadDelPrecioPorM2	98

Índice de tablas

Tabla 1 - Fuente de datos para la dimensión de distrito.....	17
Tabla 2 - Fuente de datos para la dimensión de barrio.....	18
Tabla 3 - Fuente de datos para la tabla de hechos fact_operación	20
Tabla 4 - Fuente de datos para la tabla de hechos fact_economico	21
Tabla 5 - Visualizaciones presentes en el cuadro de mando	60
Tabla 6 - Medidas DAX implementadas en el cuadro de mando	66
Tabla 7 - Tabla de Entradas y Salidas de la Calculadora de Rentabilidad.....	83

Abreviaturas y Acrónimos

UPM	Universidad Politécnica de Madrid
TFG	Trabajo de Fin de Grado
ETL	Extracción, Transformación y Carga
ELT	Variación del proceso ETL
INE	Instituto Nacional de Estadística
APIs	Interfaz de Programación de Aplicaciones
IPC	Índice de Precios al Consumo
KNIME	Konstanz Information Miner
SQL	Lenguaje de Consulta Estructurada
IPV	Índice de Precios de Vivienda
IPVA	Índice de Precios de Vivienda en Alquiler
IPC	Índice de Precios al Consumo
UX	Experiencia de usuario
KPIs	Indicadores Clave de Rendimiento
DAX	Lenguaje de fórmulas de Power BI
BI	Inteligencia de Negocio

1. Introducción

Actualmente, la toma de decisiones orientada al mercado inmobiliario ya sea para la compra o el alquiler, es un tema difícil. El tema se agudiza, sin embargo, en las grandes ciudades como Madrid, donde interactúan diversos factores como los movimientos económicos, la volatilidad de la demanda y la tendencia cambiante del mercado y la obtención de una perspectiva objetiva y clara se ve dificultada. Por otro lado, la información acerca del mercado normalmente carece de accesibilidad y comprensibilidad para el ciudadano medio, y se vuelve aún más complicado el análisis y la evaluación.

Una de las mayores barreras está en la falta de recursos que permitan analizar fácil y eficientemente la información disponible. Si bien se cuenta con algunos portales inmobiliarios y determinadas estadísticas, su interpretación a menudo necesita un alto nivel de habilidades técnicas para sacar conclusiones efectivas. Esto suscita incertidumbre y reduce la autonomía del usuario para comparar fácil y eficientemente las diversas opciones de alojamiento disponibles en el mercado.

El objetivo principal del presente TFG es diseñar una solución tecnológica para facilitar el cálculo del precio de venta o arrendamiento de viviendas en la ciudad de Madrid. Para lograrlo, se piensa desarrollar un tablero de mando interactivo a partir de datos abiertos, diseñado para visualizar la información de manera intuitiva. Esta herramienta busca habilitar a compradores e inversores, permitiéndoles acceder a datos relevantes y tomar decisiones más fundamentadas en el contexto del mercado inmobiliario. Para el cumplimiento del presente objetivo general, se han definido los siguientes objetivos específicos:

1. Diseñar y construir un DataMart en MySQL que organice y almacene de manera eficiente los datos necesarios para la estimación de precios de vivienda.
2. Incorporar procesos ETL a través del software KNIME, integrando los datos procedentes de fuentes abiertas y preparándolos para su análisis.

3. Desarrollar modelos predictivos de precios utilizando KNIME y técnicas de machine learning, con el propósito de generar estimaciones precisas y confiables.
4. Desarrollar visualizaciones interactivas en Power BI que permitan a los usuarios navegar a través del conjunto de datos de precios en función de zonas geográficas (distritos y barrios), estudiar su trayectoria histórica y efectuar sólidas comparaciones.

La motivación detrás del proyecto tiene dos dimensiones. En el nivel personal, representa la posibilidad de transferir las habilidades adquiridas a lo largo del Grado en Ingeniería del Software en la resolución de un problema práctico y de relevancia social. En el nivel colectivo, el proyecto se propone acentuar el potencial del uso de datos abiertos como medio para empoderar a la ciudadanía. En un contexto económico marcado por la incertidumbre, facilitar el acceso a información clara y comprensible puede ayudar a las personas a tomar decisiones más seguras en torno a la vivienda, un bien esencial que representa, además, una de las inversiones más importantes a lo largo de la vida.

Esta memoria se estructura en diferentes capítulos para presentar una exposición clara y detallada del trabajo realizado. Posterior a esta Introducción, se encuentra el Contexto del Proyecto, en el cual se abordan los aspectos técnicos y las decisiones de diseño tomadas. A continuación, se describe la metodología empleada para el desarrollo de la solución. En el capítulo de Implementación, se perfilan los procedimientos efectuados para la creación del DataMart, la implementación de los procedimientos ETL, el desarrollo del modelo predictivo y la creación del cuadro de mando en Microsoft Power BI. Posterior a ello, se presentan los Resultados obtenidos, acompañados del análisis correspondiente. Por último, se presentan las Conclusiones del trabajo y se plantean líneas de investigación para su posible desarrollo en futuros trabajos.

2. Estado del Arte

2.1. Fuente de los datos

En un entorno cada vez más digital, los datos abiertos se han convertido en un soporte imprescindible para proyectos que aspiran a analizar y entender realidades multifacéticas como el mercado inmobiliario. Los datos abiertos son aquellos a los que cualquier individuo tiene acceso, para usarlos y compartirlos sin limitaciones importantes, y, como resultado, se vuelven ideales para fomentar la transparencia y la accesibilidad a la información. En el caso del presente Trabajo de Fin de Grado, que persigue crear una solución para estimar precios de vivienda a través de un cuadro de mando, estos datos son cruciales.

El mercado inmobiliario tradicionalmente opaco, logra beneficiarse enormemente de esta apertura, ya que permite que los ciudadanos, investigadores, y profesionales puedan tomar decisiones más informadas basadas en información acertada y actualizada. Por ello, he optado por fuentes que no solo brindan datos variados y diversos, sino que también se complementan entre sí para brindar una visión completa del sector inmobiliario en la ciudad de Madrid.

La selección de las fuentes se ha realizado como respuesta a la demanda de unir datos detallados del mercado con datos oficiales y contextuales. El portal inmobiliario Idealista otorga un enfoque práctico y vivo, el Portal de datos abiertos del Ayuntamiento de Madrid profundiza y garantiza la fiabilidad, el Instituto Nacional de Estadística (INE), el Colegio de Registradores de la Propiedad, Bienes Muebles y Mercantiles de España y los Datos abiertos del Gobierno de España son para complementar el análisis con un panorama económico más completo. A continuación, se describe en profundidad qué aporta cada uno y el porqué son esenciales para este proyecto

2.1.1. Portal Inmobiliario

Idealista¹ es uno de los portales inmobiliarios más populares en España y una fuente imprescindible para este trabajo. Este sitio web recopila datos detallados sobre viviendas en venta y alquiler, como precios, ubicación geográfica, tamaño, número de habitaciones y otras características relevantes

¹ <https://www.idealista.com/>

de las propiedades. Su valor para un cuadro de mando inmobiliario radica en la cantidad y actualidad de la información que ofrece, lo que permite capturar las tendencias del mercado casi en tiempo real. Por ejemplo, se puede analizar cómo varían los precios según la zona o el tipo de vivienda, algo esencial para entender la dinámica de Madrid. Sin embargo, no todo es perfecto: al obtener datos mediante scraping o APIs de portales comerciales como este, existe el riesgo de sesgos. Los precios que vemos son los de oferta, no los finales de las transacciones, y las propiedades listadas podrían no reflejar todo el mercado, como aquellas gestionadas por agencias pequeñas o vendidas directamente. A pesar de estas limitaciones, he decidido incluir Idealista porque su amplitud y detalle lo convierten en un punto de partida esencial para mi análisis.




Ilustración 1 - Sección de informes de precios de vivienda publicada por Idealista

2.1.2. Portal de Datos Abiertos del Ayuntamiento de Madrid

El Portal de Datos Abiertos del Ayuntamiento de Madrid² complementa perfectamente la información de Idealista al ofrecer datos oficiales y

² <https://www.madrid.es/portal/site/munimadrid>

normalizados. Este recurso incluye conjuntos de datos como precios históricos de vivienda por distrito o barrio, estadísticas sobre el parque inmobiliario y cartografía urbana detallada. Estos datos son ideales para enriquecer el análisis, ya que permiten cruzar la información de mercado de Idealista con variables más amplias, como la evolución de precios a lo largo del tiempo o la distribución de viviendas por zonas. Lo que hace especial a esta fuente es su carácter público al ser datos oficiales, tienen una calidad garantizada, están libres de licencias restrictivas y se actualizan con una periodicidad definida, aunque no tan frecuente como la de portales privados. Frente a Idealista, el Portal ofrece una visión más objetiva y menos sesgada por intereses comerciales, lo que lo convierte en un pilar sólido para mi proyecto y una garantía de transparencia en los resultados.




Ilustración 2 - Sección "Mercado de la vivienda" del portal estadístico del Ayuntamiento de Madrid

2.1.3. INE y Datos abiertos del Gobierno de España

Finalmente, el Instituto Nacional de Estadística³ y el Portal de Datos Abiertos del Gobierno de España⁴ aportan un enfoque económico y demográfico que completa el panorama inmobiliario. Estas fuentes ofrecen indicadores clave como IPV (Índice de Precios de Vivienda), el salario medio, la evolución de la población y otras estadísticas relacionadas con la actividad económica. Aunque no están directamente ligados a los precios de las viviendas, su inclusión es crucial para entender el contexto en el que se mueven. Por

³ <https://www.ine.es/>

⁴ <https://datos.gob.es/es/>

ejemplo, un aumento en el IPC (Índice de Precios al Consumo) o una caída en el poder adquisitivo pueden influir en la demanda de viviendas y, por ende, en sus precios. El poder integrar estos factores económicos en el cuadro de mando nos puede permitir ir más allá de los datos puramente inmobiliarios y construir predicciones más robustas. Al elegir estas fuentes y al combinarlas con Idealista y el Portal del Ayuntamiento de Madrid, se puede obtener una visión integral que conecta el mercado de la vivienda con las tendencias económicas y sociales que la afectan.

En resumen, estas tres fuentes juntas forman la base de los datos del presente trabajo de fin de grado. Idealista nos da el pulso del mercado, el Portal de Datos Abiertos del Ayuntamiento de Madrid aporta rigor oficial, y el INE junto con los Datos abiertos del Gobierno de España nos ayuda a enmarcar todo en un contexto más amplio. Esta combinación es lo que hace posible un análisis completo y útil para estimar los precios de la vivienda en Madrid.




Ilustración 3 - Página del Instituto Nacional de Estadística (INE) sobre el Índice de Precios de Vivienda (IPV)

The screenshot shows the 'datos.gob.es' website interface. At the top, there's a header with the logo and navigation links. The main content area is titled 'Panel de indicadores de distritos y barrios de Madrid. Estudio sociodemográfico'. Below the title, there's a section for 'Sector público' with a 'Compartir' button. The 'Publicador' is 'Ayuntamiento de Madrid' and the 'Licencia' is 'Público'. The 'Descripción' section provides details about the data set, including its territorial scope and available formats (XLS, CSV, PDF). The 'Distribuciones' section lists four data files for download:

Formato	Nombre del archivo	Tamaño	Acción
XLS	Estructura y variables disponibles en este estudio (versión CSV)	233952 Bytes	Descargar
CSV	Estudio de indicadores de distritos y barrios 2020-2024 (versión CSV)	23764992 Bytes	Descargar
XLS	Estudio de indicadores de distritos y barrios. 2017	3807232 Bytes	Descargar
XLS	Estudio de indicadores de distritos y barrios. 2018	12396544 Bytes	Descargar

Ilustración 4 - Panel de indicadores de distritos y barrios de Madrid – Datos abiertos del Gobierno de España

2.2. Herramientas de visualización de datos

La visualización de datos se define como el proceso para representar la información a modo gráfico para hacerla accesible y fácil de entender. En proyectos de análisis de datos, este campo adquiere un significado particular, especialmente cuando se trabaja con grandes cantidades de información que resultarían difíciles de interpretar en formatos brutos como tablas y texto. El elemento clave está en que la buena representación gráfica facilita la detección de patrones, tendencias o anomalías en un corto espacio de tiempo, algo que resulta esencial en contextos donde la cantidad de datos puede abrumar. En este TFG, la visualización de datos posee un papel muy preciso, reducir la complejidad del mercado inmobiliario madrileño a algo manejable para el usuario. A través de un cuadro de mando interactivo y accesible, se pretende que personas interesadas en la compra o alquiler de una vivienda puedan consultar la información y tomar decisiones sólidas, apoyándose en gráficos que faciliten la accesibilidad a precios, ubicaciones y su evolución.

Microsoft Power BI:

Microsoft Power BI⁵ es una aplicación de Inteligencia Empresarial diseñada e implementada por Microsoft que se enfoca en el análisis de datos, creación de informes y tableros interactivos. Su arquitectura está diseñada para que la haga accesible a personas con todos los niveles de experiencia, y eso la convierte en una opción excelente para proyectos como el presente trabajo. El hecho de que se elija la aplicación Power BI no se hizo a la ligera, se destaca por su facilidad de uso, la compatibilidad para conectar varias fuentes de datos desde hojas de cálculo hasta bases de datos en la nube y sus funciones de desarrollo, como la creación automatizada de mapas o el filtro a nivel de detalle que se actualiza en vivo. Es toda la serie de características que la convierten en una poderosa y flexible opción para representar la información clara y según las necesidades del proyecto.

Entre las destacadas características de Power BI están las capas visuales y los mapas temáticos, que permiten visualizar correctamente datos geográficos, algo fundamental para este trabajo. Además, se destaca por sus posibilidades para la creación de dashboards interactivos, donde el propio usuario interactúa con los gráficos, y puede modificar aquello que visualiza en función de sus intereses. En este proyecto, se ha utilizado la versión gratuita de Power BI Desktop, que Microsoft ofrece sin coste, para representar temas como precios de vivienda por distrito y barrio en Madrid, evolución temporal del precio y comparativas visuales entre zonas. Por ejemplo, a través de mapas se destacan zonas con precios altos o bajos, mientras que los gráficos de líneas representan cómo han variado con el paso del tiempo, y los filtros permiten afinar los resultados según el tipo de operación, el año, el mes o la ubicación que el usuario quiera explorar.

2.3. Herramienta de ETL

El proceso Extracción, Transformación y Carga, acertadamente abreviado por sus siglas en inglés como ETL (Extract, transform and load), es un paso crítico en la preparación de los datos para futuros análisis. El proceso se define como la unión del conjunto de datos provenientes de diversas fuentes a un repositorio compartido, a menudo un almacén de datos, para la facilitación del análisis, inteligencia empresarial y aplicaciones para el aprendizaje automático. La necesidad de integrar información proveniente de diversas

⁵ <https://www.microsoft.com/es-es/power-platform/products/power-bi>

fuentes surge del actual y complejo entorno de datos, en el que la información se genera y almacena en sistemas heterogéneos.

El proceso ETL se ejecuta durante las tres fases claramente definidas. Primero, la extracción implica la recopilación de los datos brutos desde un conjunto variado de sistemas de origen, presentando dichas fuentes como bases de datos transaccionales, archivos planos, interfaces de programación y bases de datos en la nube. Diversas fuentes como estas resaltan el papel crucial para un sólido proceso de integración como el ETL para unificar la información dispersa. Sucesivamente, la fase de transformación se ocupa de la limpieza, formato, estructura y conversión del dato extraído a un formato analizable. Asegura este paso crucial la calidad del dato a la hora de eliminar el error, los valores faltantes, la eliminación de duplicados, la validación y estandarización, admitiendo la norma según la cual los datos brutos presentarán imperfecciones que hay que arreglar antes de poder efectuar un análisis fiable. Por último, la carga se ocupa de la escritura de los datos transformados en un sistema de destino, el cual normalmente es un almacén de datos, un lago de datos o una base de datos optimizada para la consultación analítica.

Se menciona también una variación del proceso, denominada ELT (Extracción, Carga y Transformación). En el modelo ELT, los datos se extraen y se cargan primero directamente en el sistema donde se almacenan, y después se transforman dentro de ese mismo sistema. Esta secuencia se ha hecho particularmente necesaria en el caso del almacén de datos en la nube, que poseen un gran poder de procesamiento a la hora de realizarse las transformaciones directamente en el entorno del almacenamiento. El nuevo auge del ELT se materializa como un desarrollo de las estrategias del procesamiento de datos, manteniendo la ventaja de potencia de procesamiento accesible en los almacenamientos actuales para la etapa de transformación.

En el contexto de proyectos de análisis de datos, el proceso ETL cumple un rol crucial en la preparación para la inteligencia del negocio, la analítica evolucionada y el aprendizaje automático. Uno de sus aportes más destacados es la integración de datos procedentes de sistemas dispares, ofreciendo una perspectiva unificada que permite un análisis exhaustivo. Esa habilidad para forjar una vista coherente de los datos es crucial para romper los silos informativos y para tener una comprensión integral de las actividades empresariales. Por otro lado, las soluciones ETL abren la puerta a la

automatización para las tareas repetitivas de procesamiento de datos, mejorando la eficiencia y liberando a los especialistas del tedio del manejo manual de datos, permitiéndoles enfocarse en el desarrollo de conocimiento. La automatización disminuye el esfuerzo manual y riesgo de error en la preparación de datos, con un incremento notable en la productividad.

La relevancia del ETL alcanza a la calidad, la coherencia y la utilidad de los datos. El proceso de transformación es esencial para mejorar la calidad del dato a través de la detección y corrección de errores, el manejo de valores faltantes y aseguramiento de la consistencia. Calidad de los datos es un factor fundamental, ya que los datos incorrectos pueden llevar a inferencias incorrectas y a decisiones incorrectas. El ETL también garantiza la coherencia en la normalización del formato de los datos, la unidad de medida y el esquema a lo largo de fuentes variadas. Su coherencia permite una fácil integración y comparación de información a través de múltiples sistemas. En última instancia, el ETL transforma los datos en algo más adecuado para el análisis y la elaboración de informes, ya que los prepara en un formato estandarizado y accesible. El resultado estructurado del proceso ETL apoya directamente la efectividad del análisis de datos, la visualización y la elaboración de informes, y conduce directamente a la inteligencia de negocio accionable.

En el contexto específico de este TFG, el ETL obtiene una validez especial en la preparación e integración de los datos. Para la implementación del proyecto, es crucial obtener datos provenientes de diversas fuentes potenciales, como bases de datos o archivos CSV, y unirlos en un conjunto unificado que sea idóneo para la creación de un modelo de predicción de precios de vivienda. El ETL se transforma así en el paso clave para unificar datos heterogéneos del mercado del suelo en un esquema cohesivo para el modelado. Es posible que dichos datos necesiten procedimientos de limpieza, como el procesamiento de valores faltantes y el manejo de valores atípicos, y transformaciones, como la codificación de valores categóricos, antes de poder ser utilizados para el análisis de regresión. El procedimiento específico de predicción de precios de vivienda requiere la ejecución de pasos de limpieza y transformación de datos dentro del proceso ETL para garantizar que el modelo obtenga características relevantes y alta calidad.

Las herramientas ETL facilitan la automatización de estos complicados procesos de preparación de datos, ahorrando tiempo y asegurando la

consistencia en el proceso. Tales herramientas a menudo están diseñadas para el manejo de grandes cantidades de datos, haciendo que el sistema sea fácil de expandir para futuros incrementos o conjuntos de datos mayores. Si el conjunto inicial del TFG es manejable, la implementación de una primera herramienta ETL a escala asegura una base para futuros trabajos con conjuntos de datos aún mayores. Por último, las secuencias de trabajo del proceso ETL son fácilmente reutilizables, ya que, una vez construido un pipeline, este puede conectarse a nuevos datos con un ajuste mínimo. En el caso de este TFG, la reutilización del proceso ETL permite repetir fácilmente sus fases en caso de disponer de un nuevo conjunto de datos o cuando sea necesario actualizar el análisis.

KNIME:

KNIME⁶ es un software de análisis, informes e integración de código abierto que se ofrece gratuitamente. Su carácter de código abierto lo convierte en accesible para uso universitario sin el coste asociado a las herramientas comerciales, lo cual es un aspecto a favor para los estudiantes universitarios. KNIME se destaca usando un marco visual e interactivo basado en una interfaz de tipo arrastrar y soltar para construir flujos de trabajo de datos, también llamados canalizaciones. Su interfaz visual puede ayudar a reducir la curva de aprendizaje para los estudiantes que puedan ser nuevos en tareas arduas del procesamiento de datos. Este software une diversos elementos para el aprendizaje automático y la minería de datos mediante su enfoque modular del concepto de canalización de datos. El beneficio conseguido con esta integración dentro de la misma plataforma ETL se observa en proyectos como el TFG que involucran el modelado predictivo. Por añadidura, KNIME es altamente configurable mediante un mecanismo de plugins y permite la integración de nuevos nodos o vistas del proceso. Su extensibilidad garantiza que se pueda adaptar en KNIME en la implementación adecuada para las necesidades del proyecto a través la adición de funciones o integraciones personalizadas.

La utilización de KNIME para este TFG se justifica por varias razones. En primer lugar, su interfaz visual acelera el uso y la comprensión, particularmente para un estudiante universitario. El carácter intuitivo del entorno de desarrollo visual del KNIME hace que sea una herramienta

⁶ <https://www.knime.com/>

apropiada para que se aprendan y apliquen técnicas de ciencia de datos de forma efectiva. En segundo lugar, la flexibilidad de KNIME permite la integración con otros programas y bibliotecas, como Python, que es fundamental para el modelado profesional. El hecho de que pueda integrarse con Python fusiona la programación visual con la necesidad de scripting personalizado y bibliotecas innovadoras de aprendizaje automático. En tercer lugar, un sólido apoyo comunitario está disponible a través de foros y la Community Hub de KNIME, lo que ofrece recursos y soporte cuando se necesita. Un apoyo sólido a la comunidad es fundamental para estudiantes, ya que ofrece un recurso precioso para la resolución del problema y el máximo aprendizaje profesional. Por último, la perfecta integración con Python ofrece la utilización de poderosas bibliotecas, como Pandas para la manipulación de datos y el “Scikit-learn” para el modelado de regresión. La combinación del entorno visual de KNIME y el poder de las bibliotecas de Python ofrece un entorno robusto y flexible para los requisitos analíticos de este TFG.




Ilustración 5 - Página principal del sitio oficial de KNIME

En el desarrollo del TFG, se ha hecho uso de KNIME de varias formas. Primero, se ha utilizado para conectar con el conjunto de datos, que se tenía en formato CSV. La facilidad del manejo de la entrada a múltiples formatos presentes en KNIME simplificó la etapa inicial para cargar datos para el TFG. A continuación, se hicieron operaciones de limpieza de datos en el software KNIME, como el tratamiento de los valores faltantes, el filtro para eliminar filas o columnas y la eliminación de duplicados. Los nodos visuales en el software KNIME para la limpieza de datos ofrecieron una manera controlable y transparente para la preparación de los datos para el modelado en el TFG.

2.4. Herramientas de almacenamiento de datos

Las herramientas de almacenamiento de datos son fundamentales en la infraestructura tecnológica actual. Están diseñadas para conservar, organizar y permitir el acceso seguro a información digital, abarcando desde archivos simples hasta bases de datos complejas y copias de seguridad. Hoy en día, estas soluciones han evolucionado más allá del hardware tradicional, dando paso al almacenamiento en la nube, que mejora la flexibilidad, colaboración y seguridad, permitiendo el acceso a los datos desde cualquier dispositivo con conexión.

En proyectos de análisis y visualización, como este TFG, las herramientas de almacenamiento desempeñan un papel clave al centralizar y estructurar datos provenientes de distintas fuentes, facilitando su posterior procesamiento. Su correcta elección garantiza integridad y calidad en los datos, lo que impacta directamente en la fiabilidad del análisis. Además, permiten el trabajo colaborativo mediante accesos controlados y compartición eficiente de información.

Un sistema de almacenamiento adecuado es esencial para aplicar flujos de trabajo ETL, que preparan los datos brutos para su análisis. También contribuye a la trazabilidad y reproducibilidad, permitiendo acceder a la información en el futuro y verificar los resultados. En definitiva, una herramienta de almacenamiento bien seleccionada es decisiva para el éxito de cualquier proyecto de análisis de datos, especialmente en el contexto de un TFG con recursos y tiempo limitados.

MySQL:

MySQL⁷ es un sistema gestor de bases de datos relacional de código abierto, actualmente desarrollado y distribuido por Oracle Corporation. Para este proyecto se ha empleado su versión gratuita, MySQL Community Edition, que permite el uso libre y cuenta con el respaldo de una comunidad activa de desarrolladores y usuarios. Este sistema utiliza el lenguaje de consultas estructuradas (SQL) para la creación y gestión de bases de datos relacionales organizadas en tablas con filas y columnas. Goza de una reputación consolidada por su fiabilidad, rendimiento, escalabilidad y facilidad de uso, lo que lo convierte en una opción ampliamente adoptada tanto en el ámbito académico como profesional. Su uso es común en proyectos que abarcan desde sitios web dinámicos hasta complejas soluciones empresariales con grandes volúmenes de datos. Además, MySQL destaca por eliminar costes de licencia y ofrecer flexibilidad, junto con un amplio conjunto de recursos técnicos disponibles. En este contexto, la herramienta gráfica MySQL Workbench 8.0 CE (Community Edition)⁸ ha sido utilizada como entorno de modelado y gestión visual de la base de datos, facilitando el trabajo del proyecto de manera efectiva.

La elección de MySQL para este TFG se basa en un conjunto de características y ventajas que se han encontrado particularmente idóneos para los propósitos del proyecto. Por un lado, la alta compatibilidad de MySQL con distintos sistemas operativos (Windows, Linux, macOS) y con una amplia variedad de lenguajes de programación facilita su integración en diversos entornos de desarrollo y análisis, lo que lo convierte en una opción versátil para el proyecto. Por otro lado, la disponibilidad a nivel global de una comunidad activa y variada para MySQL nos brinda un valioso apoyo a la hora de consultar, a través de la documentación detallada y del foro, y una gran cantidad de recursos para el estudio del sistema y la resolución de problemas. La comunidad representa un recurso invaluable para cualquier estudiante que enfrenta un Trabajo de Fin de Grado, especialmente en momentos de presión. El apoyo, la documentación compartida y las experiencias colectivas están al alcance y pueden marcar una gran diferencia en el desarrollo del proyecto. Por otro lado, MySQL se caracteriza también por su sencillez relativa en la instalación y la administración, accesibilidad

⁷ <https://www.mysql.com/products/community/>

⁸ <https://dev.mysql.com/downloads/workbench/>

para un usuario con un nivel técnico capacitado, pero no necesariamente experimentado, para la gestión de bases de datos. Otro aspecto a considerar fue las interfaces visuales para la gestión y diseño de las bases de datos, como se encuentran en programas como MySQL WorkBench. Por último, uno de los motivos básicos para escoger MySQL para el presente proyecto es su capacidad para ser, de manera efectiva, integrado con herramientas de análisis y visualización de datos esenciales, que son KNIME y Power BI. Su integración permite el acceso directo a las fuentes de datos almacenadas en MySQL, facilitando tanto su análisis como su visualización, y contribuyendo de manera fundamental al desarrollo del proyecto. La elección de MySQL responde, además, a su equilibrio estratégico a nivel de sistema gestor de bases de datos relacional, que proporciona un rendimiento sólido, accesibilidad, compatibilidad y, sobre todo, fácil integración en su ecosistema de herramientas. Todo ello garantiza una curva de adaptación flexible y manejable para un estudiante que ya posee nociones técnicas claras.




Ilustración 6 - MySQL Workbench 8.0 CE (Community Edition)

3. Datos de Partida

En cualquier trabajo de análisis de datos, la fiabilidad de los resultados depende crucialmente de la calidad, variedad y aptitud de fuentes. Este apartado describe a nivel de detalle las fuentes empleadas en el TFG, sus características fundamentales, proceso de obtención y tratamiento previo de datos, y limitaciones detectadas. Los conjuntos de datos abarcan información espacial (barrios y distritos de Madrid), temporal (precios de alquiler y de venta) y económica (índices macroeconómicos), y han sido recopilados con el propósito de construir un DataMart sólido que actúe como base de la capa de presentación y del modelo predictivo.

3.1 Descripción general de las fuentes de datos

Los datos utilizados proceden esencialmente de tres bloques: Dimensiones espaciales (superficie media de vivienda por distrito y barrio), hechos de operación (evolución de precios de venta y alquiler) y hechos económicos (índices macroeconómicos de inflación, salario medio e hipotecas). A continuación, se detallan cada una de estas fuentes, el modo de acceso, el período cubierto, su relevancia para el proyecto y las principales limitaciones identificadas.

3.1.1 Distritos de Madrid

La primera dimensión geográfica considerada en este proyecto se basa en las fuentes de datos denominadas "Superficie media (m²) de las viviendas por Distrito y Barrio según Tipo" y "Distritos municipales de Madrid", que son proporcionada por el portal web del Ayuntamiento de Madrid. A través de dichos conjuntos de datos, se ha obtenido información crucial como nombre y código de cada uno de los distritos, así como la superficie media en metros cuadrados, desglosada en barrio y distrito. Se eligieron estratégicamente estos conjuntos de datos, ya que ofrecían en línea de manera directa dicha información para la dimensión de distritos, maximizando así la búsqueda y ahorrando pasos en los procesos ETL en la medida de lo posible.

La importancia de esta fuente radica en que constituye la base para el proyecto al proporcionar los datos fundamentales de los distritos de Madrid, que son esenciales para su análisis. También, al proporcionar dicha información, ayuda a que la herramienta de visualización Power BI reconozca los distritos al usar mapas. Otra característica es que este conjunto de datos

también cuenta con la superficie media de las viviendas, lo cual es útil para hacer una estimación del precio total de un hogar en un determinado distrito al multiplicarlo por el precio por metro cuadrado.

Durante la fase de obtención y preparación inicial de los datos, se aplicó un proceso de filtrado para eliminar aquellas columnas no relevantes para los objetivos del proyecto. Además, se realizó una validación cruzada entre las distintas fuentes utilizadas, con el fin de asegurar la correcta identificación del código de distrito universal empleado por el Ayuntamiento de Madrid, considerada la fuente principal de datos del proyecto. No se detectaron incidencias significativas durante esta etapa.

A continuación, se presenta una tabla resumen de las fuentes de datos principales utilizadas:

Tabla 1 - Fuente de datos para la dimensión de distrito

Nombre del set de datos	Fuente	Período
Superficie media (m2) de las viviendas por Distrito y Barrio según Tipo	Ayuntamiento de Madrid	2023
Distritos municipales de Madrid	Ayuntamiento de Madrid	2023

3.1.2 Barrios de Madrid

La segunda dimensión geográfica utilizada en este proyecto se basa en la fuente de datos denominada "Superficie media (m2) de las viviendas por Distrito y Barrio según Tipo", también obtenida del portal web del Ayuntamiento de Madrid. De la misma forma que en el caso de la dimensión de distritos, se ha extraído la información referente a la dimensión barrio, como su nombre y el código de cada barrio, así como la superficie media en metros cuadrados de las viviendas, ordenado por distrito y barrio. Se escogió este conjunto de datos siguiendo el mismo criterio que para la dimensión de distritos, al buscar una fuente que ofrezca los datos esenciales de forma directa para eludir así tener que realizar un proceso de búsqueda y simplificar la realización de ETL. Dicha fuente tiene un papel fundamental en este proyecto, al ser el medio por el que consigo los datos de los barrios de Madrid, los cuales son vitales para el análisis a este nivel de granularidad. Al igual que los datos de distritos, esta información permite que Power BI identifique

los barrios al utilizar mapas. Además, al proporcionar la superficie media de las viviendas, resulta útil para calcular el precio total aproximado de una vivienda en cada barrio al multiplicarla por el precio del metro cuadrado.

A diferencia de la dimensión de distritos, para esta fuente no se identificaron limitaciones significativas. El volumen de datos es de aproximadamente 130 registros en uno de los conjuntos de datos y 170 en el otro. En cuanto a la preparación inicial, se aplicaron los mismos procesos que a la dimensión de distritos, limpiando algunas columnas que no se iban a utilizar. No se detectaron problemas durante la obtención o preparación de estos datos.

A continuación, se presenta una tabla resumen de las fuentes de datos principales utilizadas:

Tabla 2 - Fuente de datos para la dimensión de barrio

Nombre del set de datos	Fuente	Período
Superficie media (m2) de las viviendas por Distrito y Barrio según Tipo	Ayuntamiento de Madrid	2023
Barrios municipales de Madrid	Ayuntamiento de Madrid	2023

3.1.3 Evolución de Precios

Esta es la fuente de datos de mayor importancia para este proyecto, ya que sin ella el trabajo carecería de sentido. Esta fuente proporciona la evolución del precio del metro cuadrado de la vivienda, tanto para la venta como para el alquiler, en todos los distritos y barrios de Madrid. Este conjunto de datos es ofrecido por el Portal de Datos del Ayuntamiento de Madrid. En este caso, la fuente de datos “Evolución del precio de alquiler de la vivienda (€/m2) por Distrito y Barrio” y “Evolución del precio de venta de la vivienda (€/m2) por Distrito y barrio”. La información obtenida de estos conjuntos de datos es la evolución del precio de alquiler de la vivienda (€/m2) por distrito y barrio, así como la evolución del precio de venta de la vivienda (€/m2) por distrito y barrio.

Resultó ser un desafío encontrar conjuntos de datos que encajen con las especificaciones del trabajo. No fue fácil encontrar fuentes que proporcionaran la granularidad y el alcance temporal deseados. Se contactó directamente con varias alternativas, incluyendo Idealista. Si bien el portal

web de idealista proporciona datos actualizados, no proporcionó los datos históricos necesarios para observar la evolución de los precios a lo largo de varios años, ni los datos históricos detallados necesarios para un análisis exhaustivo. Aunque Idealista ofrecía una API y una fuente de datos disponible en GitHub, el número de peticiones mensuales permitidas era muy limitado, lo que restringía significativamente su utilidad para este proyecto. En segundo lugar, los datos proporcionados se basaban en anuncios de venta y alquiler, y no en transacciones reales, lo que planteó dudas sobre su validez. Sin embargo, se consideró que, para el propósito del trabajo, cuyo objetivo era proporcionar una estimación del precio del metro y no uno real (cuya adquisición se consideró fuera del alcance), esto podría ser aceptable.

Se hizo un esfuerzo por conseguir datos de años anteriores a 2020 para tener más información y, en etapas futuras, probar técnicas de aprendizaje automático para hacer predicciones. Se investigaron diversas fuentes, incluidas las del Ayuntamiento de Madrid y el Colegio de Registradores de la Propiedad, Bienes Muebles y Mercantiles de España. Sin embargo, los datos disponibles presentaban importantes limitaciones: algunos incluían únicamente información sobre compraventas y no sobre alquileres; otros ofrecían datos a nivel de barrio, pero no de distrito; y muchos mostraban períodos temporales incoherentes (por ejemplo, algunos abarcaban de 2016 a 2023, mientras que otros se limitaban a 2005-2015). Además, las metodologías empleadas variaban entre fuentes, lo que hacía inviable la homogeneización del conjunto de datos para su análisis conjunto. Se vio la posibilidad de implementar técnicas de regresión y extrapolación con Python para llenar datos faltantes y hacer predicciones futuras, y en algún momento, con KNIME y algoritmos de aprendizaje automático para tratar de deducir información a partir de los variados conjuntos de datos con metodologías distintas. Sin embargo, tras varias reconsideraciones, se decidió que no era la mejor estrategia y se dio prioridad a conseguir conjuntos de datos que compartieran metodología y cuyo rango temporal fuera constante. Uno de los objetivos del trabajo era precisamente mostrar la importancia de los datos abiertos para la toma de decisiones y las posibilidades que ofrecen. Finalmente, después de una exhaustiva búsqueda, se descubrieron dos conjuntos de datos en el Portal de Datos del Ayuntamiento de Madrid que ofrecían la evolución del precio de alquiler y venta de la vivienda por barrio y por distrito, y lo más importante, con alta granularidad mensual en su última fecha disponible, un punto que en otras fuentes no se lograba encontrar.

El rango temporal cubierto por estos conjuntos de datos abarca desde 2023 hasta 2025, y en cuanto al nivel territorial, incluyen tanto los barrios como los distritos de Madrid. La cantidad de datos en cada conjunto es de unos 4716 registros.

A continuación, se presenta una tabla resumen de las fuentes de datos principales utilizadas:

Tabla 3 - Fuente de datos para la tabla de hechos fact_operación

Nombre del set de datos	Fuente	Período
Evolución del precio de alquiler de la vivienda (€/m2) por Distrito y Barrio	Ayuntamiento de Madrid	2023-2025
Evolución del precio de venta de la vivienda (€/m2) por Distrito y barrio	Ayuntamiento de Madrid	2023-2025

3.1.4. Datos Económicos

En una etapa inicial de este proyecto, se consideró valioso contar con una tabla de hechos económicos que mostrara valores de índices económicos, salarios e hipotecas para futuras versiones del trabajo. El objetivo era analizar el posible impacto de estos valores económicos en el precio de venta y alquiler de las viviendas. Por ello, se decidió incluir una primera versión de esta tabla de hechos incorporando distintos indicadores de contexto económico, como el IPV (Índice de Precios de Vivienda), el IPVA (Índice de Precios de Vivienda en Alquiler), el IPC (Índice de Precios al Consumo), el salario medio y datos relativos a las hipotecas. Aunque estos datos no estén reflejados en su totalidad en el cuadro de mando actual, se encuentran disponibles para su uso en futuras ampliaciones del proyecto.

Se utilizaron cinco conjuntos de datos para su recopilación. Estos son la fuente principal para el IPV, el IPVA y el IPC, que corresponde al Instituto Nacional de Estadística (INE). Los datos sobre hipotecas fueron recopilados por el Colegio de Registradores de Propiedad, Bienes Muebles y Mercantiles de España, desde el Portal de Datos del Ayuntamiento de Madrid.

La importancia de esta fuente reside en su potencial para futuras incorporaciones al trabajo, permitiendo analizar la relación entre estos índices económicos y la evolución de los precios de la vivienda. Sin embargo, se identificaron limitaciones importantes, principalmente la falta de una

granularidad mensual homogénea entre todos los indicadores, ya que algunos se ofrecen trimestralmente, otros anualmente y otros mensualmente. El nivel territorial para todos ellos es la Comunidad de Madrid. Su volumen de datos es de unos 25 registros por indicador. Los procesos de limpieza, validación y filtración aplicados a estos conjuntos de datos se especificarán más adelante.

Uno de los principales problemas detectados durante la obtención y preparación fue la dificultad para unir todos los conjuntos de datos en una única tabla utilizando KNIME, debido a las diferencias en la granularidad temporal. Esta situación generó muchos huecos de datos. A pesar de esta limitación, se considera que esta tabla de hechos económicos, aunque no esté plenamente integrada en el cuadro de mando actual, representa un recurso valioso para futuras investigaciones y análisis

A continuación, se presenta una tabla resumen de las fuentes de datos principales utilizadas:

Tabla 4 - Fuente de datos para la tabla de hechos fact_economico

Nombre del set de datos	Fuente	Período
Índice de Precios de Vivienda (IPV)	INE	2011-2022
Índice de Precios de Vivienda en Alquiler (IPVA)	INE	2007-2024
Índice de Precios al Consumo (IPC)	INE	2005-2025
Salario medio anual Comunidad de Madrid	EPDATA	2008-2022
Hipoteca media (€). Tipo de interés medio. Cuota hipotecaria mensual media a 20 años y al plazo contratado (€) por Distrito y Barrio	Ayuntamiento de Madrid	2007-2023

3.2 Características generales y procesos de preparación inicial

En resumen, las fuentes de datos utilizadas en este proyecto se pueden caracterizar por los siguientes puntos: utilización principalmente de datos de tipo tabular, obtenidos de portales de datos abiertos de organismos oficiales como el Ayuntamiento de Madrid y el Instituto Nacional de Estadística (INE)

y plataformas especializadas en datos económicos como EPDATA. El enfoque temporal de los datos se centra en los años recientes, con especial énfasis en el período 2023 - 2025 para los datos de operaciones inmobiliarias, lo que garantiza la actualidad de la información para el análisis del mercado de la vivienda en Madrid. La cobertura geográfica se circunscribe a la ciudad de Madrid, con un nivel de detalle que incluye tanto la división administrativa por distritos como por barrios, permitiendo un análisis geográfico granular.

Los procesos de preparación inicial aplicados a estas fuentes de datos incluyeron principalmente el filtrado de columnas que no eran relevantes para los objetivos del proyecto, así como la validación cruzada de identificadores geográficos (como los códigos de distrito) entre diferentes conjuntos de datos para asegurar la consistencia y la correcta integración de la información. En las siguientes secciones de esta memoria, se detallarán de manera exhaustiva los procesos de Extracción, Transformación y Carga específicos aplicados a cada una de estas fuentes de datos para prepararlas para su posterior análisis y visualización en la herramienta Power BI.

4. Diseño del Datamart

4.1. Introducción al Modelo en Estrella del DataMart

La selección de un modelo en estrella para el diseño del DataMart destinado a un cuadro de mando predictivo de precios inmobiliarios en Madrid se fundamenta en su estructura fundamental y su amplia utilización en el desarrollo de almacenes de datos y data marts dimensionales. Este esquema, con su configuración a modo de estrella con tabla de hechos centrada y tablas de dimensiones laterales, se ha revelado eficiente para el manejo de consultas de análisis básicas. En el caso de un cuadro de mando predictivo orientado a los precios de la vivienda inmobiliaria, la simpleza inherente al modelo a modo de estrella se equilibra de manera ideal con la imperiosa necesidad de consultas directas y breves para analizar la tendencia de los precios con respecto a diferentes dimensiones clave, como el tiempo y el espacio. La estructura transparente del modelo permite su comprensión y navegación para los consumidores finales, quienes se comunicarán fundamentalmente con el cuadro de mando mediante la plataforma Power BI.

La decisión de adoptar un modelo en estrella y no los modelos menos normalizados, como el modelo copo de nieve, es una elección centrada deliberadamente en la simplificación de las consultas y la facilidad de comprensión antes que la exhaustiva normalización de los datos. Las unidades de dimensiones se desnormalizan como un aspecto característico de los esquemas que se dice que contienen un cierto nivel de redundancia de datos. Sin embargo, esta elección de diseño conlleva la ventaja de requerir un menor número de combinaciones (joins) durante las consultas, lo que se traduce en una mejora del rendimiento, un factor esencial para un cuadro de mando interactivo y con capacidad de respuesta. El propósito central de implementar un modelo en estrella es mejorar de forma significativa la experiencia analítica del usuario final. Este enfoque no solo simplifica la interacción con los datos, sino que también se alinea eficazmente con herramientas de inteligencia empresarial como Power BI, que están específicamente diseñadas para integrarse con modelos dimensionales. Esta compatibilidad permite una visualización más clara y una exploración más intuitiva de la información.

Dentro de este marco, el modelo en estrella ofrece una serie de ventajas clave. Una de las más destacadas es la simplicidad que aporta a las consultas. Gracias a su estructura desnormalizada, donde una tabla de hechos central se conecta directamente con múltiples tablas de dimensiones, se reducen considerablemente las uniones complejas. Esto no solo facilita la redacción de consultas SQL más directas y eficientes, sino que también mejora la comprensión general del modelo por parte de los usuarios, incluso aquellos con conocimientos técnicos limitados.

Además, el rendimiento es un factor crítico en cuadros de mando orientados a la analítica predictiva. Al reducir el número de combinaciones requeridas, el modelo de estrella permite la aceleración de la ejecución de consultas, lo que se convierte en tiempos de respuesta más cortos y visualizaciones más dinámicas dentro de Power BI. Esta fluidez es crítica para promover una interacción constante y dinámica con los datos, especialmente para entornos en los que la toma de decisiones en tiempo real es primordial.

En lo que se refiere a la escalabilidad, si bien los modelos normalizados como el esquema de copo de nieve se destacan especialmente en entornos de gran cantidad de datos y decenas de dimensiones de baja cardinalidad, el propio esquema en estrella también goza de un muy buen potencial de crecimiento. La facilidad para la incorporación de nuevas dimensiones o medidas a medida que evolucionan las necesidades del negocio lo convierte, por lo tanto, en una elección sólida y flexible, si se tiene en cuenta que los costes de almacenamiento han bajado notablemente los últimos años.

Sin embargo, se puede destacar que para situaciones muy complicadas —por ejemplo, de dimensiones muy jerárquicas o grandes— los esquemas de copo de nieve podrían tener algunos beneficios referidos a la eficiencia del almacenamiento y del mantenimiento.

Aun así, para la mayoría de los proyectos analíticos centrados en la visualización y exploración de datos, el modelo en estrella representa una opción equilibrada y altamente eficaz.

El volumen real de datos inmobiliarios para Madrid será un factor crucial para determinar las implicaciones prácticas de escalabilidad en este contexto específico. Aunque los esquemas en estrella pueden manejar cantidades significativas de datos, la posibilidad de redundancia en las tablas de dimensiones podría generar mayores requisitos de almacenamiento en comparación con un esquema de copo de nieve en ciertas situaciones. Sin embargo, para un proyecto de TFG, la escala de datos prevista para el mercado inmobiliario de Madrid podría no presentar esto como una limitación importante, y las ventajas en el rendimiento de las consultas y la simplicidad podrían superar esta posible consideración de almacenamiento.

Finalmente, la facilidad de mantenimiento es otra ventaja significativa del modelo en estrella. Su diseño directo, con una clara separación entre hechos y dimensiones, hace que el modelo de datos sea relativamente fácil de comprender, actualizar y gestionar. Esta simplicidad es especialmente beneficiosa para un proyecto como un TFG, donde la complejidad del modelo de datos debe mantenerse dentro de límites manejables.

4.2. Descripción de las Dimensiones

4.2.1. Dimension Tiempo

La tabla de dimensión `dim_tiempo` se estructura con `id_tiempo`, un entero secuencial que actuará como clave primaria, asegurando la identificación única de cada período de tiempo. Esta práctica es estándar en el modelado de datos para facilitar las uniones eficientes con las tablas de hechos. Además de la clave primaria, la tabla incluirá atributos para año, mes y trimestre. Se trata de campos que permitirán al cuadro de mando de Power BI hacer análisis temporal a diferentes niveles de granularidad, lo que facilita comparaciones interanuales, la identificación de tendencias mensuales y la evaluación del desempeño del período trimestral de los precios inmobiliarios.

La inclusión de trimestre junto con año y mes sugiere un requisito analítico específico de la necesidad de analizar las tendencias y patrones de precios a nivel trimestral, lo cual es habitual en los informes empresariales para la identificación de las variaciones estacionales y el desempeño a medio plazo. Mientras que los análisis mensuales y anuales ofrecen perspectivas de corto y largo plazo, respectivamente, el nivel trimestral aporta una visión intermedia valiosa que puede revelar ciclos de mercado que no son evidentes en otras escalas.

Actualmente, la dimensión tiempo se limita a estos tres niveles debido a la naturaleza de los datos disponibles. Sin embargo, si en fases futuras del proyecto se dispusiera de datos con mayor granularidad o se considerara relevante un análisis más detallado, esta tabla podría ampliarse fácilmente para incluir otros atributos como el número de día, el día de la semana, el semestre, el bimestre o el cuatrimestre. Esta flexibilidad permite que el modelo se adapte a nuevas necesidades analíticas sin requerir una reestructuración profunda.





Ilustración 7 - Dimensión de Tiempo

4.2.2. Dimensión Distrito

La tabla de dimensión `dim_distrito` cuenta con `id_distrito`, un entero secuencial, como su clave primaria. Los campos `cod_distrito` y `nombre` almacenarán el código y el nombre únicos de cada distrito administrativo dentro de Madrid, proporcionando atributos esenciales para el filtrado y el etiquetado de datos en el cuadro de mando. El atributo `superficie_media`, que refleja el tamaño medio de las propiedades en cada distrito, funcionará como un factor contextual fundamental para el análisis de precios. El precio por metro cuadrado puede verse influenciado significativamente por el tamaño promedio de las propiedades en un área determinada, lo que hace que este atributo sea valioso para comparaciones matizadas. El campo `zona_geográfica` permitirá una categorización de nivel superior de los distritos en zonas geográficas más amplias dentro de Madrid (Centro, Zona Norte, Zona Sur, Zona Oeste y Zona Este). Esto permitirá el análisis en conjunto y las comparativas de precios en distritos más amplios al presentar una imagen general del mercado. Incluir la variable `superficie_media` en la dimensión distrito, así como en la dimensión barrio resalta el hecho de que el tamaño de la propiedad contribuye al costo inmobiliario y hay que tenerlo en cuenta en el análisis. Al incorporar la superficie promedio directamente en las tablas de dimensiones, el cuadro de mando permitirá a los usuarios ir más allá de las simples comparaciones de precios y contextualizar estas comparaciones en función de los tamaños típicos de las propiedades predominantes en diferentes distritos, obteniendo así una comprensión más profunda de las variaciones de precios.



dim_distrito	
id_distrito	INT
cod_distrito	VARCHAR(10)
nombre_distrito	VARCHAR(100)
superficie_media_vivienda	DECIMAL(10,2)
zona_geografica	VARCHAR(20)
Indexes	
PRIMARY	
idx_dim_distrito_nombre	

Ilustración 8 - Dimensión de Distrito

4.2.3. Dimensión Barrio

La dimensión `dim_barrio` se define mediante `id_barrio`, un campo entero secuencial como clave principal. Esta tabla almacenará el código único y el nombre de cada barrio dentro de Madrid, proporcionando el segmento geográfico más granular para el análisis de precios. El campo `id_distrito` será una clave foránea que referenciará a `id_distrito` en la tabla `dim_distrito`. Esto aclara la jerarquía entre los distritos y sus respectivos barrios, permitiendo

al usuario explorar desde la visión general del distrito hasta los detalles del barrio. Al igual que en la tabla `dim_distrito`, se incluirá `superficie_media` para representar el tamaño promedio de las propiedades a nivel de barrio. Este factor dará contexto importante para el análisis de las variaciones de precios en las zonas residenciales al aceptar que incluso en un distrito el diámetro medio de las propiedades que pueden variar considerablemente. Este modelo que agrega tanto la dimensión distrito como la dimensión de barrio enfatiza la necesidad de un análisis geográfico multinivel de los precios inmobiliarios. Esto permite tanto comparaciones amplias entre distritos como información detallada y localizada dentro de barrios específicos, atendiendo a una variedad de requisitos analíticos. Los mercados inmobiliarios a menudo se caracterizan por matices a nivel de barrio que podrían quedar enmascarados al observar los promedios de distrito más amplios. Al proporcionar ambas dimensiones, el cuadro de mando permitirá a los usuarios obtener tanto una perspectiva de alto nivel como una comprensión detallada de la dinámica del mercado local.

dim_barrio	
id_barrio	INT
cod_barrio	VARCHAR(10)
nombre_barrio	VARCHAR(100)
id_distrito	INT
superficie_media_vivienda	DECIMAL(10,2)
Indexes	
PRIMARY	
idx_dim_barrio_nombre	

Ilustración 9 - Dimensión Barrio

4.3. Descripción de las Tablas de Hechos

4.3.1. Hechos de Operación

La tabla `fact_operacion` constituye el eje central del modelo en estrella diseñado para este análisis, con el objetivo de capturar y evaluar las principales métricas vinculadas a las transacciones inmobiliarias realizadas en la ciudad de Madrid. En esta tabla se almacenan indicadores clave que permiten cuantificar con precisión la actividad del mercado, tales como: `precio_m2`, que representa el valor por metro cuadrado de cada operación registrada; `variación_mensual`, `trimestral` y `anual`, que reflejan el comportamiento del precio en distintos horizontes temporales; `superficie_media`, como medida del tamaño promedio de las propiedades

involucradas; `precio_promedio_vivienda`, que expresa el coste total medio de las viviendas y `total_anual`, una métrica agregada que resume el costo total anual de la vivienda.

Este conjunto de medidas constituye una base robusta para el estudio cuantitativo del mercado y facilita la identificación de patrones y tendencias relevantes.

Para contextualizar adecuadamente estas métricas, `fact_operacion` incorpora claves foráneas que enlazan con las tablas de dimensiones correspondientes:

- `id_tiempo`, asociada a la dimensión temporal (`dim_tiempo`),
- `id_distrito`, que conecta con la dimensión geográfica a nivel distrital (`dim_distrito`),
- `id_barrio`, que permite un análisis más detallado a nivel de barrio (`dim_barrio`).

Gracias a esta estructura, el modelo habilita una exploración multidimensional de los datos, permitiendo a los usuarios aplicar filtros y segmentaciones según criterios temporales y espaciales. Esto resulta especialmente útil para generar informes dinámicos y cuadros de mando interactivos que reflejen con precisión la evolución del mercado inmobiliario en distintas zonas de la ciudad y en diferentes momentos.

Un aspecto particularmente valioso de esta tabla de hechos es la inclusión directa de métricas de variación de precios en diferentes escalas temporales (mensual, trimestral y anual). Esta decisión de diseño no es casual: responde a una intención clara de facilitar el análisis de tendencias y mejorar la capacidad de anticipación dentro del sistema. En el contexto de un cuadro de mando con enfoque predictivo, estas métricas permiten detectar rápidamente señales de cambio, evaluar la intensidad de los movimientos del mercado y orientar decisiones estratégicas basadas en datos concretos.

En conjunto, la estructura de `fact_operacion`, tanto por su contenido métrico como por su integración con las dimensiones clave, proporciona una plataforma sólida y flexible para el análisis inmobiliario, con un enfoque centrado en la escalabilidad, la precisión y la facilidad de interpretación.

fact_operacion	
id_operacion	INT
id_tiempo	INT
id_barrio	INT
id_distrito	INT
tipo_operacion	VARCHAR(50)
precio_m2	DECIMAL(10,2)
variacion_mensual	DECIMAL(5,2)
variacion_trimestral	DECIMAL(5,2)
variacion_anual	DECIMAL(5,2)
superficie_media	DECIMAL(10,2)
precio_promedio_vivienda	DECIMAL(10,2)
total_anual	DECIMAL(10,2)

Indexes	
PRIMARY	
idx_fact_operacion_tiempo	
idx_fact_operacion_barrio	
idx_fact_operacion_distrito	
idx_fact_operacion_tipo_operacion	
idx_fact_operacion_precio_m2	

Ilustración 10 - Hechos de Operación

4.3.2. Hechos económicos.

La tabla fact_economico se diseñó para almacenar una serie de indicadores macroeconómicos con potencial para impactar la dinámica del mercado inmobiliario. Los indicadores más importantes que se incluyen son el IPV, el IPVA, el IPC, el salario medio, el precio medio de las hipotecas, los tipos de interés, la cuota hipotecaria media, la accesibilidad de la vivienda, la inflación y el crecimiento económico general. Estos indicadores se utilizarán para contextualizar y pronosticar los movimientos de los precios inmobiliarios en Madrid. La tabla fact_economico se relacionará mediante la clave foránea id_tiempo. Esta decisión de diseño refleja la comprensión de que estos indicadores económicos se monitorean y reportan periódicamente (mensual, trimestral o anualmente), y que sus valores son significativos dentro de estos plazos para el mercado inmobiliario. La elección de tener una tabla de hechos para los indicadores económicos separada de otras tablas resalta el impacto significativo de estos factores externos en la configuración de los precios inmobiliarios y la importancia de tenerlos en cuenta en el modelo de predicción. El comportamiento del mercado inmobiliario no es aislado, se ve fuertemente afectado por el entorno económico en general. Al incorporar estos indicadores macroeconómicos, el cuadro de mando permitirá un análisis más holístico que considere no solo la dinámica interna del mercado, sino también las presiones y condiciones económicas externas. El diseño de la tabla de hechos económicos con un único enlace a dim_tiempo, y la ausencia de enlaces

a dimensiones geográficas, sugiere una suposición inicial de que estos indicadores macroeconómicos se considerarán a un nivel agregado para toda la región de Madrid. Las mejoras futuras podrían explorar la incorporación de datos económicos geográficamente específicos si dichos datos estuvieran disponibles y se consideraran relevantes para el análisis. Si bien los indicadores macroeconómicos, como las tasas nacionales de inflación, se informan típicamente a nivel nacional, podrían existir o estar disponibles datos económicos más localizados. El reconocimiento de este potencial para una futura granularidad permite un diseño de DataMart más adaptable.




Ilustración 11 - Hechos Económicos

4.4. Integridad Referencial y Claves

Para asegurarnos de que cada registro en nuestro DataMart sea único y fácil de identificar, todas las tablas de dimensiones como dim_tiempo, dim_distrito y dim_barrio usan un número entero que se genera automáticamente como clave principal. Esto significa que cada tabla tiene su propio identificador: id_tiempo para la tabla de tiempo, id_distrito para los distritos y id_barrio para los barrios. De la misma manera, las tablas de hechos, que son fact_operacion y fact_economico, también tienen claves principales con números enteros secuenciales, llamadas id_operacion e id_economico.

Usar estos números enteros en orden es algo muy común y recomendado en el mundo de las bases de datos. Es fundamental para que cada registro sea

único y, además, ayuda a que las consultas sean rápidas y eficientes, lo cual es súper importante cuando trabajas con un volumen grande de datos. También hace que cargar y organizar la información sea mucho más sencillo.

Ahora, pasemos a las claves foráneas, que son igual de importantes para conectar toda la información. En la tabla `fact_operacion`, los campos `id_tiempo`, `id_distrito` e `id_barrio` funcionan como claves foráneas. Esto quiere decir que conectan cada registro con las tablas de dimensiones: `id_tiempo` se enlaza con `id_tiempo` en `dim_tiempo`, `id_distrito` con `id_distrito` en `dim_distrito`, y `id_barrio` con `id_barrio` en `dim_barrio`. Estas conexiones establecen una relación donde muchas transacciones pueden estar relacionadas con el mismo período de tiempo, distrito o barrio. Por ejemplo, en un mismo mes o en un mismo barrio pueden pasar muchas transacciones inmobiliarias diferentes y estas claves nos permiten analizar eso sin problemas.

De forma similar, en la tabla `fact_economico`, el campo `id_tiempo` también actúa como clave foránea, vinculando los datos económicos a un momento específico en `dim_tiempo`. Estas reglas son esenciales para mantener todo bien relacionado y asegurarnos de que la información en el DataMart sea coherente y confiable.

La implementación de claves primarias y foráneas proporciona rutas claras y directas para la trazabilidad de los datos en todo el DataMart. Al seguir las relaciones de clave foránea desde un registro en cualquiera de las tablas de hechos hasta las claves primarias en las tablas de dimensiones, se vuelve sencillo identificar el tiempo, el distrito y el barrio específicos asociados con ese registro. Esto es crucial para comprender el contexto de los datos a un nivel granular. Además, esta estructura de claves bien definida simplifica significativamente el diseño y la ejecución de consultas SQL para la extracción y manipulación de datos. Por ejemplo, para analizar el precio promedio por metro cuadrado de las propiedades vendidas en un distrito particular durante un año específico, sería suficiente una simple operación de unión entre la tabla `fact_operacion` y la tabla `dim_distrito` en el campo `id_distrito`, combinada con el filtrado basado en el año en la tabla `dim_tiempo`. La característica del esquema en estrella de requerir menos uniones en comparación con esquemas más complejos como el copo de nieve también contribuye a un rendimiento de las consultas SQL más simple y a menudo más eficiente.

El enfoque en la trazabilidad de los datos y el diseño orientado a la simplificación de las consultas SQL refuerza la elección del esquema en estrella como base para un DataMart analítico. Esta decisión resulta especialmente acertada en el contexto de su integración con herramientas de inteligencia empresarial como Power BI, donde se espera que los usuarios realicen exploraciones dinámicas y análisis interactivos de la información.

Las relaciones bien definidas y estrictamente aplicadas entre las tablas, establecidas mediante claves primarias y foráneas, no solo aseguran la integridad referencial de los datos, sino que también aportan claridad al modelo. Esto beneficia tanto a los desarrolladores responsables de construir y mantener los cuadros de mando como a los usuarios finales, quienes pueden entender con mayor facilidad cómo se relacionan los distintos elementos del modelo y cómo extraer de ellos insights significativos.

En definitiva, esta estructura relacional coherente y accesible agiliza el desarrollo, mejora la usabilidad del modelo y fortalece la calidad del análisis, contribuyendo directamente a una experiencia más fluida, confiable y productiva en entornos de BI.

4.5. Diagrama Relacional y Topología en Estrella

El diagrama relacional de nuestro DataMart propuesto se adhiere a una topología en estrella. En esta configuración, las tablas `fact_operacion` y `fact_economico` se ubican en el centro, representando los hechos principales relacionados con las transacciones inmobiliarias y las condiciones económicas. Estas tablas de hechos centrales están directamente vinculadas y rodeadas por las tablas de dimensiones: `dim_tiempo`, `dim_distrito` y `dim_barrio`.

Una característica definitoria de la estructura en estrella es que carece de cualquier relación o vinculación directa entre las propias tablas de dimensiones. Por ejemplo, mientras las tablas `dim_distrito` y `dim_barrio` tienen una relación directa con la tabla `fact_operacion` (a través de sus respectivas claves foráneas), no se establece ninguna ruta de unión directa entre `dim_distrito` y `dim_barrio` fuera de su vinculación en común con la base de hechos.

La relación jerárquica distrito-barrio se mantiene implícita a través de sus respectivos vínculos independientes con las transacciones inmobiliarias. Esta decisión estructural refuerza la simplicidad del modelo en estrella y lo diferencia de otras configuraciones de almacenamiento de datos, como el

esquema en copo de nieve, en el que las dimensiones se descomponen en múltiples subdimensiones normalizadas, generando una red de relaciones más compleja y ramificada.

Cabe destacar que, aunque a simple vista pueda parecer un modelo en copo de nieve por la relación entre `dim_barrio` y `dim_distrito`, esta conexión no responde a necesidades analíticas. No existe ninguna consulta en la que se necesite navegar desde un barrio a su distrito o viceversa. La relación se ha incluido únicamente para respetar la coherencia de los datos, ya que un barrio pertenece a un distrito. Por tanto, el modelo sigue siendo un esquema en estrella en su propósito y funcionamiento analítico.




Ilustración 12 - DataMart Mercado Inmobiliario

5. Proceso de ETL

5.1 Introducción general al proceso ETL

El proceso ETL, que significa Extracción, Transformación y Carga, es una parte clave en cualquier proyecto que trabaje con datos, como este Trabajo de Fin de Grado (TFG). Como ya se explicó en el apartado "Estado del Arte", el ETL permite tomar datos en bruto de diferentes fuentes, limpiarlos, organizarlos y cargarlos en una base de datos lista para ser analizada. En este proyecto, se diseñan y ejecutan cuatro procesos ETL para alimentar las tablas de dimensiones (`dim_distrito` y `dim_barrio`) y las tablas de hechos (`fact_operacion` y `fact_economico`). La tabla `dim_tiempo` no necesita un proceso ETL porque se genera directamente con una consulta SQL de tipo INSERT.

A continuación, detallo cada etapa del proceso ETL, empezando por la extracción, siguiendo con la transformación y terminando con la carga.

5.2 Extracción de datos (Extract)

La mayoría de los datos se descargaron manualmente desde el portal de datos abiertos del Ayuntamiento de Madrid, mayoritariamente en formato CSV delimitado por comas, y algunos en formato Excel (.xlsx). No supuso ninguna dificultad, ya que herramientas como KNIME permiten leer y manipular distintos formatos de manera eficiente.

Las fuentes específicas de los datos ya fueron detalladas en el apartado "Datos de partida", por lo que no se considera necesario repetirlas aquí.

El proceso de descarga fue manual, pero muy ágil: simplemente se seleccionaron los conjuntos de datos deseados, los atributos relevantes, el orden de las columnas y el formato (en columnas o filas), todo ello mediante una interfaz muy intuitiva.

5.3 Transformación de datos (Transform)

La transformación es la etapa más compleja del ETL, donde los datos en bruto se limpian, organizan y combinan para que tengan el formato correcto antes de cargarlos en la base de datos. A continuación, se explica cómo se diseñaron los procesos ETL para las dimensiones `dim_distrito`, `dim_barrio` y las tablas de hechos `Fact_operacion` y `Fact_economico` usando KNIME, detallando los nodos utilizados y los pasos seguidos.

5.3.1 ETL para dim_distrito

El objetivo para la dimensión dim_distrito era obtener el nombre de cada distrito, su superficie media y su zona geográfica. Para lograrlo, se combinaron dos conjuntos de datos: uno con la superficie media de las viviendas y otro con información geográfica. Ambos conjuntos usaban un código identificador único para cada distrito, lo que facilitó mucho su unión.

El primer conjunto de datos utilizado, correspondiente a la superficie media de las viviendas, tiene como fuente original al Colegio de Registradores de la Propiedad, Bienes Muebles y Mercantiles de España, aunque fue obtenido a través del Portal de Datos del Ayuntamiento de Madrid. El archivo, en formato Excel, incluía una tabla con los nombres de los distritos y la superficie media de las viviendas, desglosada por tipo (nueva o usada) y por nivel territorial (distrito o barrio). Dado el enfoque de simplificación adoptado en este trabajo, se optó por utilizar únicamente el promedio total, sin distinguir entre tipos de vivienda.

Acceso a Banco Datos	EDIFICACIÓN Y VIVIENDA. MERCADO DE LA VIVIENDA. COMPRA-VENTA DE LA VIVIENDA. ESTADÍSTICA REGISTRAL INMOBILIARIA			
Índice				
Datos	3. Superficie media (m ²) de las viviendas por Tipo, Distrito y Barrio ⁽¹⁾			
Distrito ⁽³⁾	Total ⁽²⁾	Nuevas		Usadas
		Libres	VPO	
2023				
Ciudad de Madrid	81,83	85,60	91,31	80,90
01. Centro	72,27	91,79	0,00	71,54
011. Palacio	81,95	87,42	0,00	81,15
012. Embajadores	54,57	0,00	0,00	54,40
013. Cortes	93,14	0,00	0,00	93,14
014. Justicia	93,39	0,00	0,00	93,39
015. Universidad	67,87	100,60	0,00	66,19
016. Sol	95,80	0,00	0,00	95,29

Ilustración 13 - Superficie media (m²) de las viviendas por Tipo, Distrito y Barrio

El flujo de trabajo en KNIME comenzó con el nodo Excel Reader, que se usó para cargar el archivo Excel. Este nodo nos permite leer la tabla y trabajar con las columnas relevantes.

Excel Reader



Ilustración 14 - Nodo Excel Reader

Luego, con el nodo Column Renamer, se asigna los nombres a las columnas, ya que al momento de extraer los datos los nombres de las columnas desaparecen por defecto.

Column Renamer




Ilustración 15 - Nodo Column Renamer

Después, se utilizó el nodo String Manipulation dos veces: primero, para extraer el código del distrito en una columna separada, y segundo, para aislar el nombre del distrito en otra columna. Esto era necesario para usar el código como punto de unión con el segundo conjunto de datos. Si se quería renombrar las nuevas columnas, se podía hacer directamente en el nodo String Manipulation o con otro Column Renamer.




Ilustración 16 - Nodos String Manipulation

El segundo conjunto de datos “Distritos municipales de Madrid”, que aporta la información geográfica, también se obtuvo del portal del Ayuntamiento de Madrid en formato Excel. Con otro nodo Excel Reader, se cargó este archivo, omitiendo columnas irrelevantes como Shape_leng, Shape_area, cod_dis y los nombres de distritos en mayúsculas.

	Column	New name	Type
::	☐ Shape_Leng		D Number (double)
::	☐ Shape_Area		D Number (double)
::	☐ COD_DIS		I Number (integer)
::	☒ COD_DIS_TX		S String
::	☒ NOMBRE		S String
::	☐ DISTRI_MAY		S String
::	☐ DISTRI_MT		S String
::	☒ ZONA		S String
::	☒ <any unknown new column>		? Default

Ilustración 17 - Asignación de datos útiles de distritos

Shape_Leng	Shape_Area	COD_DIS	COD_DIS_TX	NOMBRE	DISTRI_MAY	DISTRI_MT	ZONA
10.304,08	5.228.245,51	1	01	Centro	CENTRO	CENTRO	Centro
12.806,77	6.462.175,91	2	02	Arganzuela	ARGANZUELA	ARGANZUELA	Centro
9.523,89	5.466.211,19	3	03	Retiro	RETIRO	RETIRO	Centro
10.866,34	5.392.404,10	4	04	Salamanca	SALAMANCA	SALAMANCA	Centro
13.396,82	9.175.482,12	5	05	Chamartín	CHAMARTIN	CHAMARTIN	Zona Norte
9.919,06	5.374.725,25	6	06	Tetuán	TETUAN	TETUAN	Zona Norte
9.019,54	4.679.185,07	7	07	Chamberí	CHAMBERI	CHAMBERI	Centro
94.480,91	237.838.267,09	8	08	Fuencarral - El Pardo	FUENCARRAL - EL PARDO	FUENCARRAL - EL PARDO	Zona Norte
41.016,91	46.586.949,56	9	09	Moncloa - Aravaca	MONCLOA - ARAVACA	MONCLOA - ARAVACA	Zona Oeste
28.142,97	25.410.387,60	10	10	Latina	LATINA	LATINA	Zona Oeste
18.083,30	14.048.315,85	11	11	Carabanchel	CARABANCHEL	CARABANCHEL	Zona Sur
11.878,91	7.777.716,75	12	12	Usera	USERA	USERA	Zona Sur
17.263,77	14.968.605,87	13	13	Puente de Vallecas	PUENTE DE VALLECAS	PUENTE DE VALLECAS	Zona Sur
10.814,07	6.103.167,75	14	14	Moratalaz	MORATALAZ	MORATALAZ	Zona Este
21.524,70	11.425.677,96	15	15	Ciudad Lineal	CIUDAD LINEAL	CIUDAD LINEAL	Zona Este
27.366,86	27.623.983,98	16	16	Hortaleza	HORTALEZA	HORTALEZA	Zona Norte
18.370,60	20.194.322,83	17	17	Villaverde	VILLVERDE	VILLVERDE	Zona Sur
33.498,40	51.453.754,55	18	18	Villa de Vallecas	VILLA DE VALLECAS	VILLA DE VALLECAS	Zona Sur
34.269,62	35.262.737,30	19	19	Vicalvaro	VICALVARO	VICALVARO	Zona Este
26.767,80	22.289.895,00	20	20	San Blas - Canillejas	SAN BLAS - CANILLEJAS	SAN BLAS - CANILLEJAS	Zona Este
29.554,99	41.716.342,84	21	21	Barajas	BARAJAS	BARAJAS	Zona Norte

Ilustración 18 - Set de datos de Distritos

Opcionalmente, se usó el nodo Column Renamer para hacer los nombres de las columnas más claros.

Para combinar ambos conjuntos, se utilizó el nodo Joiner, uniendo las tablas por el código del distrito.




Ilustración 19 - Nodo Joiner

Match

☒ All of the following
 ☐ Any of the following

Top input ('left' table)
 Bottom input ('right' table)

cod_distrito

▼

cod_distrito

▼

🗑️

Ilustración 20 - Unión por Código de distrito

Este nodo nos permite excluir columnas innecesarias, como la que mezclaba el nombre del distrito con su código. Además, se configuró el nodo para filtrar solo los registros de distritos, usando la opción "Matching Rows", ya que no necesitaba información de barrios en esta tabla.




Ilustración 21 - Obtenemos la fila coincidente

Al final, nos quedamos con la superficie media del primer conjunto y los datos geográficos del segundo.




Ilustración 22 - Datos incluidos y excluidos

Para cargar los datos transformados en la base de datos MySQL, se usó el nodo MySQL Connector. Este nodo nos permite configurar el hostname, el puerto, el nombre de la base de datos y las credenciales de acceso.

MySQL Connector



Ilustración 23 - Nodo MySql Connector

Para simplificar la gestión de credenciales, se utilizó el nodo Credential Widget, que automatiza este paso de forma más práctica.

Credentials Widget




Ilustración 24 - Nodo Credentials Widget

Finalmente, con el nodo DB Insert, se configuró la tabla de destino `dim_distrito` y se especificó las columnas donde se cargarían los datos. Este paso aseguró que la información transformada se almacenara correctamente en MySQL, lista para ser usada en el cuadro de mando.

DB Insert



Ilustración 25 - Nodo Insert




Ilustración 26 - Configuración del Nodo Insert para Dim_Distrito




Ilustración 27 - ETL Dim_Distrito

5.3.2. ETL para dim_barrio

El proceso ETL para la dimensión dim_barrio fue bastante parecido, pero con algunos detalles adicionales porque los barrios dependen de los distritos. Se usó el mismo conjunto de datos inicial en formato Excel que para los de dim_distrito, ya que incluye la superficie media tanto para distritos como para barrios. De nuevo, solo nos quedamos con el promedio total de superficie, sin distinguir entre viviendas nuevas o usadas.

El flujo comienza con el nodo Excel Reader para cargar el archivo. Luego, con Column Renamer, se asignó nombres a las columnas, que venían sin etiquetas claras. Igual que antes, se usó String Manipulation dos veces: una para separar el código del barrio en una nueva columna y otra para extraer el nombre del barrio. Estas columnas podían renombrarse en el mismo nodo o con un Column Renamer adicional.




Ilustración 28 - Separación del código de la zona

Para la construcción de la segunda tabla, se utilizó el archivo “Barrios municipales de Madrid”, disponible en formato Excel a través del portal del Ayuntamiento de Madrid. Este archivo fue de utilidad para filtrar correctamente los barrios y confirmar la coherencia de los datos territoriales empleados en el proyecto.

CODDIS	COD_DIS_TX	NOMDIS	COD_BAR	COD_DISBAR	COD_DISB	NUM_BAR	NOMBRE	BARRIO_MAY	BARRIO_MT	FCH_ALTA	FCH_BAJA	OBSERVACIONES	APROBACION	Shape_Leng	Shape_Area
1	01	Centro	011	11	1-1	1	Palacio	PALACIO	PALACIO					3,754.83	1,469,905.93
1	01	Centro	012	12	1-2	2	Embajadores	EMBAJADORES	EMBAJADORES					4,275.23	1,033,724.49
1	01	Centro	013	13	1-3	3	Cortes	CORTES	CORTES					3,731.08	591,874.24
1	01	Centro	014	14	1-4	4	Justicia	JUSTICIA	JUSTICIA					3,597.42	739,413.49
1	01	Centro	015	15	1-5	5	Universidad	UNIVERSIDAD	UNIVERSIDAD					4,060.08	948,026.38
1	01	Centro	016	16	1-6	6	Sol	SOL	SOL					2,719.29	445,300.97
2	02	Argenzuela	021	21	2-1	1	Imperial	IMPERIAL	IMPERIAL					4,557.94	967,479.32
2	02	Argenzuela	022	22	2-2	2	Acacias	ACACIAS	ACACIAS					3,950.33	1,073,436.83
2	02	Argenzuela	023	23	2-3	3	Chopera	CHOPERA	CHOPERA					3,203.41	567,766.98
2	02	Argenzuela	024	24	2-4	4	Legazpi	LEGAZPI	LEGAZPI					5,141.64	1,414,470.94
2	02	Argenzuela	025	25	2-5	5	Delicias	DELICIAS	DELICIAS					4,818.00	1,054,679.05
2	02	Argenzuela	026	26	2-6	6	Palos de la Frontera	PALOS DE LA FRONTERA	PALOS DE LA FRONTERA					3,647.75	648,441.64
2	02	Argenzuela	027	27	2-7	7	Atocha	ATOCHA	ATOCHA					4,957.69	735,681.16

Ilustración 29 - Set de datos de Barrios

Con Excel Reader, se cargó este archivo, descartando columnas que no se necesitaban, y opcionalmente el uso de Column Renamer para renombrar las columnas. Luego, se unieron ambas tablas con el nodo Joiner, usando el código del barrio como clave de unión. Se configuró el nodo para incluir solo los registros de barrios con "Matching Rows" y se excluyeron las columnas sobrantes, quedándonos con la superficie media del primer conjunto y la información específica de barrios del segundo.

Top input ('left' table): cod_ubicacion

Bottom input ('right' table): cod_barrio

Join type: Matching Rows

Includes: superficie_media_vivienda

Excludes: Zona, Nueva_Libre, Nueva_VPO, Usada, cod_ubicacion, nombre_ubicacion

Ilustración 30 - Configuración del nodo Joiner

A diferencia de dim_distrito, la tabla dim_barrio necesita el campo id_distrito como clave foránea, ya que los barrios están vinculados a los distritos. Por eso, se hizo el ETL de dim_distrito primero. Para obtener el id_distrito, se usó el nodo DB Query Reader para consultar la tabla dim_distrito en MySQL y extraer el código y el identificador de cada distrito.



Ilustración 31 - Nodo DB Query Reader

Luego, con otro Joiner, se unió la información con la tabla de barrios, usando el código del distrito como enlace. Se seleccionaron los atributos necesarios, se excluyeron los que no se iban a utilizar y se utilizó "Matching Rows" para filtrarlos.

Para cargar los datos transformados en la base de datos MySQL, se usó el nodo MySQL Connector y para simplificar la gestión de credenciales, se utilizó nuevamente el nodo Credential Widget.

Finalmente, con el nodo DB Insert, se configuró la tabla de destino dim_barrio especificando las columnas donde se cargarían los datos.




Ilustración 32 - Configuración del Nodo Insert para Dim_Barrio




Ilustración 33 - ETL Dim_Barrio

5.3.3. ETL para Fact_Operacion

El ETL de la tabla de hechos Fact_Operacion utiliza el conjunto de datos "Evolución del precio de alquiler de la vivienda (€/m2) por Distrito y Barrio", cuya fuente es Idealista y se encuentra disponible en el portal de datos del Ayuntamiento de Madrid en formato CSV.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
1	E. Edificación Vivienda														
2	Mercado de la vivienda														
3	Precios de la vivienda														
4	4.3.21.D. Evolución del precio de alquiler de la vivienda (€/m2) por Distrito y Barrio														
5				Enero	Febrero	Marzo	Abril	Mayo	Junio	Julio	Agosto	Septiembre	Octubre	Noviembre	Diciembre
6	2023	01. Centro	011. Palacio	19,2	19,57	19,19	19,7	19,44	19,11	19,23	19,45	19,5	20,53	21,54	21,95
7	2023	01. Centro	012. Embajad	19,82	20	19,57	19,39	19,37	19,38	19,36	19,54	19,75	20	20,56	20,79
8	2023	01. Centro	013. Cortes	20	20	19,3	20	20,42	20,02	20	19,98	20,39	20,87	21,82	21,82
9	2023	01. Centro	014. Justicia	22,61	22,13	21,55	21,76	22,31	22,14	22,46	22,41	22,06	23,4	23,83	24,49
10	2023	01. Centro	015. Universid	20,35	20,89	20,18	20,53	20,91	20,79	20,69	20,82	21,11	21,82	22,11	22,62
11	2023	01. Centro	016. Sol	19,19	20,13	19,42	19,97	20,1	20,67	20,67	20,83	21,64	21,43	21,43	20,42
12	2023	02. Arganzuelo	021. Imperial	15,58	15,83	16,3	16,5	16,83	16,51	16,42	16,15	16,48	17,13	17,92	18,13
13	2023	02. Arganzuelo	022. Acacias	16,42	16,67	17,25	17,44	16,67	17	16,67	16,67	17,39	17,73	17,78	18,46
14	2023	02. Arganzuelo	023. Chopera	16,55	16	15,96	15,44	15,22	15,38	15,83	16,92	17,22	16,67	16,98	17,27
15	2023	02. Arganzuelo	024. Legazpi	15,26	15,53	15,71	15,74	15,67	15,58	15,54	15,5	16	16,43	15,96	15,65
16	2023	02. Arganzuelo	025. Delicias	15,83	15,67	15,94	16	16,5	16,67	17,27	17,41	17,5	17,59	17,39	17,31
17	2023	02. Arganzuelo	026. Palos de	17,14	17,43	16,87	16,87	17,17	17,28	17,42	17,86	17,78	17,59	17,86	18,67
18	2023	02. Arganzuelo	027. Atocha	..	..	..	..	..	..	..	..	..	..	..	..
19	2023	03. Retiro	031. Pacifico	15,93	16,45	16,68	16,67	16,67	16,24	16,45	16,36	16,54	16,91	16,94	17,74
20	2023	03. Retiro	032. Adelfas	16	15,81	15,28	15,91	15,38	15,5	15,38	16,19	16,36	16,67	16	15,89
21	2023	03. Retiro	033. Estrella	15,05	14,74	14,96	15	15,71	16,3	15,71	15,67	16,59	..	..	..
22	2023	03. Retiro	034. Ibiza	18,75	18,64	18,64	19,23	19,35	19,69	19,5	19,47	19,63	20	19,95	20,54
23	2023	03. Retiro	035. Los Jerón	19,2	19,2	18,5	18,33	18,33	..	..	..	..	..	..	..
24	2023	03. Retiro	036. Niño Jesu	15,67	15,61	16,58	16,87	16,26	16,61	16,88	17,34	17,86	18,51	18,99	18,45
25	2023	04. Chamartín	041. Plaza de	22,75	22,68	22,64	22,66	22,6	22,75	22,75	22,65	22,6	22,74	22,45	22,54

Ilustración 34 - Set de datos Evolución del precio de alquiler de la vivienda (€/m2) por Distrito y Barrio

A diferencia de otros casos donde trabajamos con Excel, en esta ocasión usamos el nodo CSV Reader, por lo que no necesitamos transformar previamente nuestro archivo. Este set de datos contiene en la primera columna el año, el distrito y el barrio, y en las columnas siguientes los meses del año, con el precio por metro cuadrado como contenido.

En el nodo CSV Reader configuramos el delimitador de columnas a ";" y marcamos la opción "Has column header". En la sección "Limit Rows" delimitamos el archivo para que solo se lea la tabla de datos, evitando cualquier descripción adicional, como se muestra en la imagen.




Ilustración 35 - Configuración del nodo CSV Reader

Una vez cargados los datos, debemos darles la forma deseada según el diseño de nuestra base de datos. Para ello, usamos el nodo Unpivot, que transforma las columnas de los meses en filas, generando una nueva columna llamada "mes" con todos los meses.



Ilustración 36 - Nodo Unpivot




Ilustración 37 - Configuración del nodo Unpivot

Después, necesitamos convertir los nombres de los meses en su valor numérico. Hay muchas formas de hacerlo, pero la más sencilla es con el nodo Rule Engine, que permite crear reglas personalizadas. En nuestro caso, especificamos que, si el mes es "enero", se le asigne "1", y así sucesivamente hasta "diciembre". Esto genera una nueva columna con los meses como números del 1 al 12.



Ilustración 38 - Nodo Rule Engine

Al igual que hicimos con las dimensiones anteriores, debemos separar el código que viene junto al nombre del distrito y del barrio. Para eso utilizamos el nodo String Manipulation, que nos permite aplicar expresiones sobre cadenas de texto y extraer o modificar su contenido. Lo bueno de este conjunto de datos es que ya incluye tanto datos de distritos como de barrios, por lo que

no tenemos que depender de otro conjunto de datos que pueda haber sido calculado de manera distinta y afectar la integridad del análisis.




Ilustración 39 - configuración del nodo String Manipulation para el código de los distritos

Después, debemos obtener el `id_tiempo`, que representa el año y mes correspondiente. Esto puede hacerse de dos formas: una es consultando la tabla de tiempo en la base de datos con el nodo DB Query Reader, y la otra es creando una columna directamente en KNIME con el año y el mes combinados. Como buscamos que el ETL sea lo más simple y rápido posible, optamos por no generar más nodos y usar directamente el identificador desde el nodo SQL, ya que esta tabla es estática y cargada previamente.




Ilustración 40- configuración del nodo String Manipulation para el código de tiempo

Posteriormente, usamos el nodo Column Filter para eliminar columnas innecesarias y quedarnos solo con el precio por metro cuadrado, el código de distrito, el código de barrio y el id_tiempo. Luego aplicamos el nodo Row Filter para eliminar filas con valores nulos o iguales a cero, que no nos aportan nada al análisis.




Ilustración 41 - Configuración del nodo Column Filter




Ilustración 42 - configuración del nodo Row Filter

A continuación, es necesario convertir los identificadores de distrito y barrio a tipo entero, y el precio a tipo decimal (double), de acuerdo con el modelo de nuestra base de datos. Si no hacemos esto, KNIME nos lanzará un error al momento de insertar los datos por incompatibilidad de tipos. Además, como estos datos corresponden únicamente a precios de alquiler por metro cuadrado, necesitamos identificarlos dentro de la tabla. Para eso, usamos el nodo Constant Value Column, que permite añadir una nueva columna con un valor fijo, en este caso algo como "alquiler" o "renta".




Ilustración 43 - Nodo String to Number

Constant Value Column



Ilustración 44 - Nodo Constant Value Column




Ilustración 45 - Configuración del nodo Constant Value Column

Sin embargo, surgió un inconveniente: al contener datos de distritos y barrios juntos, la columna de código de barrio también incluye valores del 01 al 21 que realmente pertenecen a los distritos. Como vimos en la dimensión de barrios, no existen códigos de barrio de dos dígitos, sino de tres. Para evitar modificar nuestra dimensión de barrios o el datamart, decidimos que cuando el código de distrito y el de barrio sean iguales, se sustituya el código de barrio por "000", indicando que no corresponde a un barrio específico, sino solo al distrito. Esto puede hacerse con una consulta SQL o dentro de KNIME. En nuestro caso lo resolvemos con el nodo Python Script, que permite ejecutar código Python directamente sobre los datos. Gracias a la librería pandas, es muy sencillo aplicar esta lógica, evitando el uso de varios nodos y manteniendo el flujo más limpio.

```
INSERT INTO Dim_Barrio (cod_barrio, nombre_barrio, id_distrito, superficie_media_vivienda)
VALUES ('000', 'no aplica', 22, 0);
```

Ilustración 46 - Consulta para añadir el nuevo valor "000"

Python Script (legacy)



Ilustración 47 - Nodo Python Script

En este mismo nodo de Python Script, aprovechamos para calcular nuevas medidas como las variaciones temporales. Estas medidas no estaban

incluidas en el conjunto de datos original, por lo que las calculamos manualmente. Usando las librerías pandas y numpy, primero limpiamos la columna de precios y la convertimos a formato numérico, asegurando que los separadores decimales sean los correctos. También convertimos el id_tiempo a número para ordenar cronológicamente. Luego, agrupamos los datos por distrito y barrio, y calculamos las variaciones mensuales, trimestrales y anuales en porcentaje con respecto a 1, 3 y 12 meses atrás. Estas nuevas columnas se integran en el mismo DataFrame, que finalmente se devuelve como salida.

(El cálculo de estas variaciones temporales se realizó mediante un script en Python, cuya configuración completa puede consultarse en el Anexo A.)




Ilustración 48 - Configuración de Python Script para obtener las variaciones temporales

Después, necesitábamos calcular otras medidas como el precio medio de vivienda y el total anual estimado. Para eso, debemos conocer las superficies promedio de vivienda por distrito y barrio. Estas superficies ya están incluidas en nuestras dimensiones, así que utilizamos el MySQL Connector, el Credential Widget y el nodo DB Query Reader para hacer dos consultas y obtener las tablas de distritos y barrios, que unimos con la principal.

En este nuevo script, tomamos las tres tablas (principal, distrito y barrio) y realizamos un proceso de enriquecimiento. Primero ajustamos los nombres y

tipos de columnas, luego hacemos los joins para incluir los identificadores y las superficies medias. Según si el dato corresponde a un distrito genérico o un barrio, seleccionamos la superficie adecuada. Después calculamos el precio medio de una vivienda (multiplicando el precio por m² por la superficie) y el ingreso anual estimado (multiplicando por 12). Por último, limpiamos los datos, redondeamos los valores y seleccionamos solo las columnas que nos interesan.

(El cálculo de las medidas restantes se realizó mediante un script en Python, cuya configuración completa puede consultarse en el Anexo B.)




Ilustración 49 - Configuración de Python Script para obtener las medidas restantes

Con esto ya tenemos lista nuestra primera tabla con datos de alquiler. Para los datos de venta de vivienda, usamos el conjunto de datos "Evolución del precio de venta de la vivienda (€/m²) por Distrito y Barrio", que tiene exactamente la misma estructura que el de alquiler. Gracias a esto, podemos reutilizar toda la secuencia de nodos anterior sin cambios.

A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
E. Edificación y Vivienda														
Mercado de la vivienda														
Precios de la vivienda														
4.3.15.C. Evolución del precio de venta de la vivienda (€/m2) por Distrito y barrio														
			Enero	Febrero	Marzo	Abril	Mayo	Junio	Julio	Agosto	Septiembre	Octubre	Noviembre	Diciembre
2023 01. Centro	011. Palacio		5.068	5.104	5.130	5.215	5.259	5.190	5.188	5.179	5.238	5.342	5.554	5.639
2023 01. Centro	012. Embajad		4.306	4.281	4.286	4.330	4.415	4.474	4.479	4.524	4.544	4.591	4.607	4.589
2023 01. Centro	013. Cortes		5.751	5.751	5.889	6.147	6.148	5.902	5.902	5.952	6.200	6.223	6.282	6.476
2023 01. Centro	014. Justicia		6.066	6.159	6.178	6.380	6.625	6.649	6.879	7.024	7.137	7.250	7.452	7.402
2023 01. Centro	015. Universid		5.439	5.471	5.584	5.878	5.656	5.745	5.789	5.782	5.879	6.006	6.126	6.276
2023 01. Centro	016. Sol		5.704	5.842	6.074	6.046	6.154	6.202	6.207	6.261	6.276	6.515	6.568	6.876
2023 02. Arganzuelo	021. Imperial		4.527	4.495	4.455	4.574	4.690	4.750	4.706	4.714	4.714	4.691	4.668	4.595
2023 02. Arganzuelo	022. Acacias		4.452	4.406	4.434	4.460	4.483	4.410	4.387	4.460	4.460	4.495	4.443	4.500
2023 02. Arganzuelo	023. Chopera		3.950	3.950	3.981	3.986	4.000	4.000	4.028	4.161	4.214	4.210	4.246	4.156
2023 02. Arganzuelo	024. Legazpi		4.956	4.956	4.868	4.839	4.938	4.889	4.948	4.936	4.937	4.887	4.988	4.942
2023 02. Arganzuelo	025. Delicias		4.302	4.368	4.360	4.360	4.325	4.254	4.256	4.290	4.262	4.291	4.262	4.312
2023 02. Arganzuelo	026. Palos de		4.299	4.285	4.285	4.348	4.300	4.411	4.589	4.519	4.569	4.601	4.694	4.694
2023 02. Arganzuelo	027. Atocha													
2023 03. Retiro	031. Pacífico		4.390	4.318	4.349	4.408	4.462	4.457	4.457	4.532	4.571	4.500	4.525	4.485
2023 03. Retiro	032. Adelfas		4.487	4.512	4.453	4.343	4.355	4.383	4.375	4.375	4.307	4.318	4.375	4.375
2023 03. Retiro	033. Estrella		4.393	4.373	4.372	4.425	4.471	4.489	4.512	4.480	4.448	4.565	4.567	4.565
2023 03. Retiro	034. Ibiza		5.979	5.869	5.987	6.115	6.384	6.377	6.410	6.563	6.625	6.563	6.655	6.784
2023 03. Retiro	035. Los Jerón		7.115	6.965	6.965	6.908	6.792	6.833	6.857	6.888	6.877	7.196	7.196	7.255
2023 03. Retiro	036. Niño Jesú		4.957	5.107	5.154	5.038	5.108	5.227	5.290	5.363	5.409	5.064	5.076	5.361

Ilustración 50 - Conjunto de datos de Evolución del precio de venta de la vivienda (€/m2) por Distrito y Barrio

Una vez obtenida nuestra segunda tabla, que incluye todos los cálculos e indicadores para los precios de venta, las unimos con la tabla de alquiler usando el nodo Concatenate, que permite fusionar dos tablas con la misma estructura.

Concatenate



Ilustración 51 - Nodo Concatenate

Para terminar, convertimos los valores NaN a null, ya que MySQL no reconoce NaN como nulo. Esto lo hicimos con el nodo Column Expressions, que funciona como un mini editor para transformar columnas sin necesidad de usar scripts más complejos.

Column Expressions (legacy)



Ilustración 52 - Nodo Column Expressions




Ilustración 53 - Configuración del Nodo Column Expressions

Finalmente, cargamos los datos a la tabla Fact_Operacion usando el nodo DB Insert.



Ilustración 54 - ETL de Fact Operación

5.3.4. ETL para Fact_Economico

Para el último proceso ETL, utilizamos cinco conjuntos de datos: IPV (Índice de Precios de Vivienda), IPVA (Índice de Precios de Vivienda en Alquiler), IPC (Índice de Precios al Consumo), la evolución del salario medio anual de la Comunidad de Madrid y la hipoteca media. Como se mencionó previamente, esta dimensión está pensada para implementaciones futuras, por lo que se consideró conveniente mostrar una primera aproximación de cómo sería su proceso ETL. En este caso, al tratarse de datos que agrupan diferentes medidas económicas que no se encuentran en un único archivo, sino en varios, fue necesario tratar cada uno por separado.

Para cada conjunto de datos en formato CSV se empleó el nodo CSV Reader para extraer la información. En el caso del IPVA, tras la extracción se utilizó el nodo Pivot, que permite transformar filas en columnas, es decir, realizar

una operación de pivoteo similar a una tabla dinámica en Excel o al método `pivot()` en pandas.




Ilustración 55 - Nodo Pivot




Ilustración 56 - Configuración del nodo Pivot

En este caso, agrupamos los datos por el campo "Período". Como los datos son anuales, creamos una nueva columna con el identificador de tiempo, asignando el número 12 como valor fijo del mes. Luego, excluimos la columna de período con el nodo Column Filter, renombramos las columnas con Column Renamer para que coincidan con los nombres de la tabla de destino, y finalmente usamos String to Number para convertir las variaciones a valores numéricos.

Por otro lado, para el IPV, después de extraer los datos, aplicamos el nodo Table Transposer, que intercambia las filas y columnas de la tabla.




Ilustración 57 - Nodo Transposer

Posteriormente, con el nodo RowID generamos un índice único por fila, y con String Manipulation extraemos los números relevantes y generamos el identificador de tiempo para cada fila. Después, filtramos las columnas innecesarias con Column Filter y volvemos a aplicar Pivot para agrupar los

datos por el nuevo identificador de tiempo. A continuación, renombramos las columnas, convertimos las variaciones a tipo numérico con String to Number y excluimos las columnas sobrantes con un segundo Column Filter.

Para el IPC, nuevamente utilizamos Pivot para agrupar por período. Sin embargo, en este caso, el período contiene una letra "M" que no es útil para nuestro análisis, por lo que la eliminamos con String Manipulation. Una vez que obtenemos una nueva columna con el período limpio, eliminamos la original con Column Filter y renombramos las columnas con Column Renamer.



Ilustración 58 - Nodo RowID

En cuanto a los datos de salario medio, debido a su estructura no fue necesario aplicar ninguna transformación de pivoteo. Solo usamos String Manipulation para construir el identificador de tiempo, eliminamos la columna "Año" con Column Filter y renombramos los campos con Column Renamer.

Para los datos de hipotecas, sí fue necesario intercambiar filas por columnas y viceversa, utilizando primero Table Transposer y luego Pivot para adecuar la estructura. Posteriormente generamos el identificador de tiempo con String Manipulation, eliminamos la columna "Año" con Column Filter, transformamos los valores a numéricos con String to Number y, como en los demás casos, renombramos las columnas con Column Renamer.

Una vez preparadas todas las tablas individuales, procedimos a unir las utilizando el nodo Joiner, que permite combinar dos tablas a la vez, por lo que el proceso se realizó de manera progresiva, tabla por tabla. Tras unir todos los conjuntos de datos, utilizamos tres nodos Math Formula para calcular las siguientes métricas: índice de accesibilidad a la vivienda, inflación del precio de la vivienda y crecimiento del mercado. Finalmente, insertamos los datos resultantes en la base de datos con el nodo DB Insert.

Dado que se trata de valores independientes, provenientes de distintas fuentes y con estructuras temporales diversas, es esperable encontrar numerosos valores ausentes. No obstante, es importante destacar que esta tabla de hechos fue concebida con la intención de, en un futuro, conectar datos económicos con la evolución del precio de venta o alquiler de la vivienda. Por

ello, se consideró adecuado incluir esta primera versión como una aproximación al potencial que puede ofrecer esta tabla de hechos dentro del Data Mart.




Ilustración 59 - ETL Fact Económico

6. Capa de presentación

La capa de presentación constituye la interfaz visual a través de la cual los usuarios finales interactúan con el sistema de análisis inmobiliario desarrollado. Es fundamental destacar que el presente nivel ha sido desarrollado a través de Power BI priorizando la claridad, la facilidad de uso y la utilidad para la toma de decisiones informadas sobre el mercado de vivienda en Madrid. Esta capa es fundamental, ya que transforma los datos brutos y los análisis complejos en información accesible y accionable, sirviendo como el punto directo de interacción para los usuarios. De esa manera, la presentación ha sido desarrollada con la prioridad de optimizar la experiencia del usuario para garantizar una fácil navegación e interpretación precisa.

6.1. Diseño general del cuadro de mando

El cuadro de mando presenta una disposición lógica y clara, estructurada en tres áreas principales que facilitan la comprensión y la interacción del usuario. Esta división tripartita asegura un flujo de información coherente, guiando al usuario desde la segmentación general hasta los análisis detallados.

6.1.1. Área Superior: Filtros de Segmentación

En la parte superior del dashboard se ubican los controles de filtro primarios, incluyendo "Año", "Mes", "Tipo de operación", "Distrito" y "Barrio". Esta posición estratégica no es arbitraria, se alinea con las prácticas estándar en el diseño de cuadros de mando, donde los controles globales se sitúan en la zona de acceso más inmediato. Al colocar los filtros en esta área, el diseño empodera a los usuarios para definir el contexto de su análisis antes de sumergirse en las visualizaciones específicas. Esta aproximación transforma la interacción de una mera personalización a un control activo sobre el flujo de información. La aplicación dinámica de estos filtros significa que cada visualización, ya sean KPIs, mapas o gráficos, se adapta instantáneamente, proporcionando una vista contextualmente relevante del mercado de vivienda en Madrid. Esto mejora significativamente la capacidad del usuario para realizar análisis ad-hoc y responder a preguntas específicas sin necesidad de generar informes personalizados, fomentando así un entorno de Business Intelligence de autoservicio. La reducción de la carga cognitiva y la

aceleración del proceso analítico son consecuencias directas de esta decisión de diseño, apoyando directamente el objetivo de facilitar la toma de decisiones informadas.

6.1.2. Zona Central: Indicadores Clave y Visualizaciones Destacadas

La zona central del cuadro de mando está dedicada a los indicadores clave de rendimiento (KPIs) y a visualizaciones de alto impacto, como mapas y rankings. Esta área actúa como el "corazón" del dashboard, proporcionando una visión general rápida del estado del mercado y destacando las métricas más relevantes a primera vista. La elección de agrupar KPIs y visualizaciones prominentes en esta sección central responde a una jerarquía de información estratégica. El objetivo es ofrecer a los usuarios las percepciones más críticas y agregadas de un solo vistazo, permitiendo una evaluación rápida de la salud general del mercado y la identificación de áreas de interés inmediato, como distritos con precios elevados. Esta filosofía de diseño prioriza la comprensión ágil y la accionabilidad inmediata, sirviendo como un resumen ejecutivo antes de cualquier inmersión analítica más profunda. De este modo, se optimiza la experiencia inicial del usuario al presentar la información esencial de manera destacada, reduciendo el tiempo necesario para comprender el estado actual del mercado e identificar posibles áreas para una investigación más exhaustiva.




Ilustración 60 - Zona Central del cuadro de mando

6.1.3. Zona Inferior: Gráficas Analíticas Detalladas

En la parte inferior se disponen gráficas más analíticas, incluyendo comparativas, tendencias temporales y relaciones. Esta sección está diseñada para el usuario que busca un análisis más profundo y detallado, permitiendo explorar las interrelaciones entre variables y la evolución del mercado a lo largo del tiempo. La ubicación de gráficos analíticos detallados en la sección inferior ejemplifica el principio de divulgación progresiva. Los usuarios son presentados primero con una visión general (área central) y los medios para filtrar (área superior). Solo después de obtener una comprensión general o identificar áreas de interés específicas, se les anima a profundizar en análisis más complejos y granulares. Este enfoque previene la sobrecarga de información y permite a los usuarios explorar los datos a su propio ritmo, avanzando desde el resumen hasta el detalle. El flujo de trabajo analítico estructurado que se deriva de esta disposición facilita que las observaciones de alto nivel conduzcan a investigaciones dirigidas de tendencias, correlaciones y rendimiento comparativo. Esta estrategia de diseño asegura que el cuadro de mando atienda a una base de usuarios diversa, desde aquellos que necesitan resúmenes rápidos hasta quienes requieren una exploración exhaustiva de datos para la planificación estratégica.




Ilustración 61 - Zona Inferior del cuadro de mando

6.1.4. Coherencia Visual y Guía del Usuario

El diseño general se apoya en una paleta de colores coherente, dominada por tonos verdes, azules y neutros, y en una tipografía clara. La elección de colores como el verde y el azul a menudo se asocia con la estabilidad, la confianza y el crecimiento, lo cual es apropiado para el análisis financiero e inmobiliario. Esta paleta no es meramente estética, establece un lenguaje visual semántico que contribuye a la legibilidad de los datos y reduce la carga cognitiva. Por ejemplo, en los mapas, los colores más oscuros se utilizan consistentemente para indicar un mayor precio por metro cuadrado, creando una jerarquía visual inmediata que facilita la identificación rápida de zonas de interés. Se utilizan iconos y tarjetas informativas estratégicamente para guiar al usuario

en la interpretación de los datos, proporcionando señales visuales intuitivas y resúmenes concisos. Esta consistencia deliberada en el diseño visual es una piedra angular de la visualización de datos efectiva, asegurando que la representación visual en sí misma ayude a la comprensión, en lugar de obstaculizarla. La interfaz se vuelve más fácil de aprender y recordar, lo que lleva a mayores tasas de adopción y a una utilización más eficaz de los datos.

6.2. Filtros disponibles

Los filtros interactivos, que son un componente crítico en la capa de presentación, permiten al usuario ajustar y personalizar la visualización del panel de control en función de sus necesidades de análisis particulares de una manera dinámica. Para la exploración detallada de las tendencias del mercado de la vivienda en Madrid, los controles de segmentación son un estándar y permiten al panel ser robusto y sensible.

6.2.1. Año y Mes

Estos filtros temporales permiten al usuario visualizar tendencias a lo largo del tiempo o identificar patrones de estacionalidad en el mercado inmobiliario. Son fundamentales para el análisis de la evolución de precios, rentabilidad y volumen de operaciones, facilitando la detección de picos, valles y cambios sostenidos que son indicativos de ciclos de mercado.

6.2.2. Tipo de Operación:

Este filtro dicotómico permite al usuario segmentar los datos entre operaciones de "alquiler" o "venta". Esta distinción es fundamental, ya que las dinámicas de mercado, los precios y las rentabilidades pueden variar significativamente entre ambos tipos de transacciones, requiriendo un análisis diferenciado para cada segmento.

6.2.3. Distrito y Barrio:

Estos filtros geográficos permiten al usuario concentrarse en áreas específicas de Madrid, desde lo macro, como los distritos, hasta lo micro, como los barrios. La granularidad es crítica para identificar las oportunidades de inversión local y para comprender las dinámicas de submercado dentro de la ciudad, permitiendo un análisis de micro tendencias

6.2.4. Aplicación Dinámica:

Debe tenerse especialmente en cuenta que estos filtros se aplican dinámicamente a prácticamente todas las visualizaciones en el tablero del panel. La aplicación dinámica de múltiples filtros granulares no es solo una especificación técnica, es un habilitador crítico de la analítica de autoservicio. Al permitir a los usuarios combinar y aplicar libremente filtros por año, mes, tipo de operación, distrito y barrio, el tablero los habilita para formular y probar sus propias hipótesis sobre el mercado de vivienda de Madrid. Por ejemplo, un usuario en cuestión puede rápidamente comparar “precios de alquiler en Salamanca en el tercer trimestre de 2023” con “precios de alquiler en Chamberí en el mismo año”, y viceversa. Es esta capacidad de navegación la que hace que el tablero en cuestión sea una herramienta de análisis de exploración de datos para el usuario en cuestión, lo que le permite descubrir implicaciones y patrones matizados que se cubren por completo en las perspectivas agregadas sin la ayuda de un experto o resolver la necesidad de generar un informe personalizado. Este nivel de interactividad es lo que contribuye en gran medida a la cantidad de análisis y la utilidad del cuadro de mando, lo que lo hace atractivo para la planificación y la investigación de mercado basada en evidencia.

Comparación de Barrios y Distritos



Ilustración 62 - Zona de Comparación de precios por distritos o barrios

6.3. Visualizaciones y su propósito

El cuadro de mando unificado incorpora una amplia gama de visualizaciones, cada una elegida por su idoneidad para transmitir aspectos particulares del mercado de vivienda de Madrid de la manera más efectiva posible. La diversidad de gráficos empleados garantiza que se examinen varias dimensiones de la actividad inmobiliaria, desde la geoespacial hasta las dependencias temporales y las correlaciones entre variables analizadas. Se presenta a continuación una vista general de las visualizaciones utilizadas y su rol en la experiencia del usuario final:

Tabla 5 - Visualizaciones presentes en el cuadro de mando

Visualización	Tipo de Gráfico	Propósito y Utilidad
Mapa de precios por m ² por distrito	Mapa temático	Permite identificar de un vistazo las zonas más caras o baratas de Madrid. Útil para analizar desigualdades territoriales.
Mapa de precios por m ² por barrio	Mapa temático	Nivel de detalle superior que muestra la variación de precios dentro de cada distrito. Ayuda a detectar oportunidades localizadas.
KPIs globales (precio m ² , precio medio vivienda, variación mensual y anual, rentabilidad bruta)	Tarjetas	Muestran los valores medios agregados, ayudando a evaluar rápidamente el estado general del mercado.
Ranking de precios por m ² (distritos y barrios)	Barras horizontales	Indica cuáles son las zonas más caras y baratas. Ayuda a comparar extremos del mercado.
Top 5 distritos/barrios más caros y baratos	Listado simple	Resume de forma sencilla dónde están los valores

		extremos, facilitando la toma rápida de decisiones.
Evolución mensual del precio por m ²	Gráfico de líneas	Muestra cómo cambian los precios mes a mes, útil para identificar tendencias, picos y bajadas.
Comparativa entre dos barrios o distritos	Conjunto de KPIs + líneas	Permite al usuario comparar directamente dos zonas en cuanto a precio medio, variación trimestral y rentabilidad. Muy útil para decidir entre dos opciones de inversión.
Comparativa de precio y rentabilidad por zona	Columnas + línea	Relaciona el coste de entrada con la rentabilidad esperada, lo que es clave para evaluar el retorno de inversión.
Relación entre precio por m ² y rentabilidad bruta anual	Diagrama de dispersión	Muestra cómo se relacionan ambas métricas. Ayuda a identificar zonas con mejor equilibrio precio-rentabilidad.
Mapa de calor de precios por mes y distrito	Matriz	Visualiza la estacionalidad y fluctuaciones mensuales por distrito. Es útil para detectar mejores meses para comprar o alquilar.
Relación entre rentabilidad y volatilidad	Dispersión	Analiza el riesgo (volatilidad del precio) frente a la rentabilidad esperada. Permite identificar zonas más estables o riesgosas.

6.4. Ayudas contextuales para el usuario

Para mejorar la experiencia del usuario en gran medida y ayudar a la interpretación de los datos, se integraron mecanismos de ayuda contextual directamente en el cuadro de mandos. Concretamente, los botones informativos, de forma muy común se representan con un icono ‘i’ de información, de forma estratégica junto a algunas visualizaciones clave.

Al interactuar con estos botones (al pasar el cursor), se activa la visualización de una descripción concisa. Esta descripción tiene como objetivo dilucidar el significado del gráfico o métrica específica y proporcionar orientación sobre su correcta interpretación.

Esta funcionalidad es particularmente crucial para usuarios que podrían no poseer una formación extensa en análisis de datos o un conocimiento profundo del dominio específico del mercado inmobiliario. La inclusión de botones de ayuda contextual representa una decisión de diseño deliberada para reducir la brecha de conocimiento entre los creadores de datos y los consumidores de datos. Va más allá de la mera visualización de información para educar activamente al usuario sobre cómo interpretar los datos correctamente. Al proporcionar explicaciones inmediatas y en contexto, el cuadro de mando no solo facilita la comprensión de visualizaciones complejas, sino que también enseña implícitamente a los usuarios sobre las métricas subyacentes y su significado. Esto, a su vez, les empodera para convertirse en consumidores de datos más sofisticados con el tiempo, lo que se traduce en una toma de decisiones más precisa y segura. Esta característica transforma el cuadro de mando de una simple herramienta de informes en una plataforma de aprendizaje, mejorando significativamente su propuesta de valor para diversos grupos de usuarios.




Ilustración 63 - Funcionamiento del botón informativo

6.5. Experiencia de usuario (UX)

El diseño de la capa de presentación ha priorizado meticulosamente la Experiencia de Usuario (UX), adhiriéndose a principios que garantizan una interacción intuitiva, eficiente y estéticamente agradable. Este enfoque en la UX es fundamental para la adopción exitosa y la utilización efectiva del sistema analítico.

6.5.1. Diseño Limpio y Claro

Se ha establecido como objetivo primordial una interfaz limpia, desprovista de elementos visuales superfluos. Cada visualización se ha incluido con un propósito específico para aportar un valor distinto, evitando la redundancia y asegurando que la atención del usuario se dirija hacia las implicaciones significativas de los datos. Esta simplicidad reduce la carga cognitiva y mejora la legibilidad general.

6.5.2. Uso Coherente y Semántico del Color

La paleta de colores utilizada no solo tiene un valor estético, sino que también lleva un significado semántico que ayuda a comprender visualmente los datos. Por ejemplo, en los mapas geográficos, los tonos más oscuros se usan de manera consistente para mostrar un precio por metro cuadrado más alto, creando un tipo de jerarquía visual que muestra directamente las zonas más valiosas de la región en cuestión. Esta consistencia semántica es clave para una comprensión intuitiva.

6.5.3. Navegación Clara e Intuitiva

La disposición general y los patrones de interacción siguen un patrón general de estructura de la información para una navegación clara e intuitiva entre de la parte superior a la inferior y la vista de análisis general a detallada. La coherencia en la disposición de los elementos y la interactividad predecible contribuyen a una experiencia de usuario fluida y sin frustraciones.

6.5.4. Facilitación de la Toma de Decisiones

El cuadro de mando está destinado a permitir que incluso los usuarios sin experiencia previa tomen decisiones rápidas e informadas sobre las oportunidades de inversión o alquiler en el mercado inmobiliario de Madrid. Esto se logra mediante una combinación de lenguaje visual accesible, controles interactivos y soporte contextual. El enfoque holístico de la UX, que abarca la claridad visual, la codificación semántica del color y la navegación intuitiva, no se limita a hacer que el cuadro de mando sea "fácil de usar"; es una decisión de diseño estratégica que impacta directamente en la eficacia del dashboard como sistema de apoyo a la decisión. Al minimizar la carga cognitiva (interfaz limpia), proporcionar señales visuales inmediatas (colores semánticos) y asegurar una exploración sin esfuerzo (navegación clara), el cuadro de mando reduce la barrera de entrada para usuarios de todas las competencias técnicas. Esto permite que una audiencia más amplia, incluidos aquellos sin experiencia en análisis de datos, comprenda rápidamente las complejas dinámicas del mercado y traduzca las implicaciones en acciones tangibles, como identificar áreas de inversión lucrativas u ubicaciones óptimas para el alquiler. La UX, por lo tanto, actúa como un puente crítico entre los datos y la decisión, haciendo que la información sea verdaderamente accionable. Este enfoque demuestra una comprensión madura de los principios de ingeniería de software que se extienden más allá de la mera funcionalidad para abarcar el aspecto crítico de la interacción humano-computadora, asegurando la utilidad y el impacto del sistema en el mundo real.

6.6. Uso de medidas personalizadas en Power BI

Fuera de la presentación visual básica y las funciones de filtrado, un aspecto técnico importante de la capa de presentación es la incorporación de medidas calculadas personalizadas dentro de Power BI. Las medidas, definidas en el con lenguaje DAX, son críticas en la creación de análisis en forma de

indicadores avanzados para el modelo analítico de datos, aumentando significativamente la riqueza analítica del cuadro de mando. Esta sección explora la racionalidad detrás de su uso y destaca algunas de las medidas más relevantes implementadas.

6.6.1. Racionalidad para el Uso de Medidas Personalizadas

La adopción de medidas personalizadas en Power BI se fundamenta en varias ventajas operativas y de rendimiento:

Cálculo Dinámico:

Las medidas DAX permiten el cálculo de promedios, variaciones o rankings de manera dinámica, adaptándose instantáneamente a los filtros activos seleccionados por el usuario. Esto garantiza que todas las métricas mostradas sean siempre contextualmente relevantes, proporcionando una visión precisa del mercado en función de los criterios de selección.

Construcción de Métricas Complejas:

Posibilitan la creación de métricas sofisticadas que no están directamente disponibles en el conjunto de datos brutos, como estimaciones de rentabilidad o indicadores de volatilidad, mediante la combinación y transformación de puntos de datos existentes. Esto amplía significativamente la capacidad analítica del dashboard.

Optimización del Rendimiento:

Al definir medidas en lugar de crear columnas calculadas adicionales en el modelo de datos, el cuadro de mando optimiza el rendimiento y reduce el tamaño del modelo, ya que los cálculos se realizan sobre la marcha solo cuando son requeridos por la visualización. Esta estrategia minimiza la huella de memoria y mejora la velocidad de respuesta.

Recálculo Automático:

Los resultados de estas medidas se recalculan y actualizan automáticamente en tiempo real a medida que los usuarios interactúan con filtros y segmentadores, proporcionando una experiencia analítica fluida y altamente receptiva.

Medidas Implementadas Más Relevantes:

La siguiente tabla resume algunas de las medidas DAX personalizadas clave desarrolladas para este cuadro de mando y sus funciones específicas:

Tabla 6 - Medidas DAX implementadas en el cuadro de mando

Medida	Propósito
PrecioMedioVenta y PrecioMedioAlquiler	Calculan dinámicamente el precio promedio por vivienda, diferenciando entre operaciones de venta o alquiler.
RentabilidadBruta	Estima la rentabilidad anual de una vivienda, permitiendo al usuario evaluar qué zonas son más rentables para inversión.
Top5VentaBarMasBaratos / Top5VentaBarMasCaros / Top5VentaDisMasCaros / Top5VentaDisMasBaratos	Identifican automáticamente los barrios y distritos más caros o baratos en venta. Se actualizan en tiempo real con los filtros.
Variación trimestral, mensual, y anual decimal	Versiones formateadas de las variaciones de precio como porcentaje decimal para una mejor visualización en tarjetas o matrices.
VolatilidadPrecio_m2	Mide la desviación estándar de los precios por m ² en una zona, permitiendo estimar el riesgo o estabilidad del mercado en ese distrito o barrio.

(La construcción de las medidas DAX necesarias se llevó a cabo directamente en Power BI, y su código completo puede consultarse en el Anexo C.)

Estas medidas son, en esencia, las "reglas de negocio" o "algoritmos analíticos" que impulsan las implicaciones dinámicas presentadas al usuario.

6.6.2. Ventajas del Enfoque de Medidas Personalizadas

La adopción de medidas personalizadas en Power BI ofrece ventajas significativas que contribuyen a la robustez y sostenibilidad del sistema:

Escalabilidad:

Al ser medidas dinámicas, no requieren una recarga de datos para obtener nuevos cálculos, lo que facilita el crecimiento futuro y la expansión de datos sin cambios arquitectónicos significativos.

Interactividad Mejorada:

Se actualizan en tiempo real según los filtros aplicados, presentando al usuario información siempre relevante al contexto actual y fomentando un entorno analítico altamente interactivo.

Claridad y Formato:

Las medidas pueden formatearse con precisión (por ejemplo, moneda, porcentaje, número) según su uso previsto, lo que mejora considerablemente la legibilidad y la comprensión dentro de las visualizaciones.

Flexibilidad y Mantenimiento:

Pueden modificarse o extenderse fácilmente sin alterar el modelo de datos base, lo que proporciona agilidad para adaptarse a los requisitos analíticos cambiantes y simplifica el mantenimiento a largo plazo.

Las ventajas de utilizar medidas DAX personalizadas (escalabilidad, interactividad, flexibilidad) no son meramente beneficios funcionales; representan decisiones arquitectónicas fundamentales que contribuyen a la robustez y la preparación para el futuro del sistema analítico. Al abstraer cálculos complejos en medidas, el modelo de datos permanece ligero y eficiente, lo que promueve un mejor rendimiento y un mantenimiento más sencillo. Este enfoque es congruente con los principios de modularidad y separación de responsabilidades en ingeniería de software, la lógica de transformación de los datos detrás de las medidas DAX se encuentra separada del almacenamiento de los datos brutos. Esta elección de diseño asegura que el cuadro de mando puede evolucionar con nuevas fuentes de datos o requisitos analíticos sin necesidad de reestructurar la infraestructura de datos subyacente por completo. Por lo tanto, el sistema adquiere un alto nivel de adaptabilidad y sostenibilidad a largo plazo.

7. Resultados

Este apartado detalla los logros tangibles y las capacidades funcionales logradas mediante el desarrollo del cuadro de mando interactivo en Power BI para la investigación de mercado de las viviendas en Madrid. Describe lo que el sistema hace posible y las capacidades que habilita para los usuarios, las perspectivas accionables que ofrece y cómo impulsa directamente la toma de decisiones informadas en el esfuerzo inmobiliario.

7.1. Logros Fundamentales del Cuadro de Mando

El proyecto ha resultado en el desarrollo de una poderosa herramienta analítica que redefine la comprensión del mercado inmobiliario madrileño. La consecución de este cuadro de mando representa un avance significativo en la accesibilidad y la profundidad del análisis de datos para el sector.

7.1.1. Desarrollo de una Plataforma Analítica Integral

El objetivo principal de este proyecto es el exitoso diseño e implementación de un cuadro de mando en Power BI. Más allá de las tablas de datos complejas, esta plataforma presenta una compleja vista multidimensional sobre cómo deben interpretarse los precios de las propiedades, la rentabilidad y el mercado en general en Madrid representa la culminación de un proceso de ingeniería de software que ha transformado datos brutos en inteligencia de mercado estructurada y accesible.

La plataforma integra eficazmente filtros temporales, como el año y el mes, geográficos, como el distrito y el barrio, y transaccionales, diferenciando entre operaciones de alquiler o venta. Esta integración, combinada con una variedad de visualizaciones (incluyendo KPIs, mapas, tendencias y análisis comparativos) y medidas calculadas, significa que el sistema no solo presenta conjuntos de datos dispares, sino que crea un entorno analítico unificado. Esta consolidación es fundamental para obtener una comprensión holística del mercado y evitar decisiones fragmentadas, lo que constituye un avance significativo en la ingeniería de datos. Al romper con los silos de datos tradicionales (como hojas de cálculo separadas para ventas y alquileres o diferentes períodos), el cuadro de mando sintetiza la información en una única fuente de verdad interactiva, permitiendo una visión completa y coherente del mercado inmobiliario.




Ilustración 64 - Cuadro de mando Insight Madrid

7.1.2. Capacitación del Usuario No Técnico

Un logro crucial es el diseño del cuadro de mando, que prioriza la accesibilidad y la interacción intuitiva, permitiendo a individuos sin conocimientos técnicos en análisis de datos extraer información significativa. Se ha puesto especial énfasis en la usabilidad para universalizar el acceso a la inteligencia de mercado.

El cuadro de mando incorpora cálculos complejos, como la *RentabilidadBruta* y la *VolatilidadPrecio_m2*, métricas típicamente asociadas con el análisis financiero avanzado. Sin embargo, el diseño explícito de la experiencia de usuario, caracterizado por una interfaz limpia y ayudas contextuales a través de botones informativos ("i") junto a las visualizaciones, busca hacer que estas métricas sofisticadas sean comprensibles para una audiencia general. Esto significa que el proyecto ha logrado democratizar el acceso a capacidades analíticas avanzadas. Va más allá de simplemente presentar datos, haciendo que la ciencia de datos compleja sea accesible y accionable para usuarios cotidianos. Este enfoque aborda un desafío clave en la inteligencia de negocios moderna y es un testimonio de la eficacia de la ingeniería de software orientada al usuario.




Ilustración 65 - Gráfico de rentabilidad y volatilidad con tooltip explicativo visible

7.1.3. Exploración Dinámica e Interactiva del Mercado

El cuadro de mando ofrece una experiencia de usuario dinámica, permitiendo ajustes en tiempo real y una exploración de datos personalizada. Esto lo convierte en una herramienta analítica viva y receptiva, superando las limitaciones de los informes estáticos.

La capacidad de filtrado dinámico y el recálculo en tiempo real de las medidas DAX significan que el cuadro de mando proporciona inteligencia contextual. En lugar de una vista fija, los usuarios pueden adaptar instantáneamente los datos a sus consultas específicas, por ejemplo, pueden investigar la tendencia de precios de alquiler en un distrito específico durante un trimestre particular. Este nivel de capacidad permite un análisis de micromercado altamente granular, lo que es mucho más potente para la toma de decisiones que las tendencias macro. La implicación es un cambio del consumo pasivo de datos a una investigación de mercado activa y personalizada, empoderando al usuario con la capacidad de explorar el mercado según sus necesidades específicas.




Ilustración 66 - Filtros activos y medidas recalculadas del mes de Julio del año 2024




Ilustración 67- Filtros activos y medidas recalculadas del mes de Noviembre del año 2024

7.2. Capacidades Funcionales y Experiencia del Usuario Final

Esta sección detalla las capacidades interactivas específicas disponibles para el usuario final, ilustrando cómo el cuadro de mando facilita la interacción directa con los datos para responder preguntas concretas sobre el mercado inmobiliario de Madrid. Se enfatiza la facilidad de uso y la amplitud de las acciones analíticas que un usuario puede realizar.

7.2.1. Filtrado y Segmentación Granular del Mercado

Los usuarios pueden definir con precisión su área de interés aplicando múltiples filtros, lo que permite un análisis altamente dirigido de segmentos de mercado específicos. Esta capacidad es fundamental para obtener una visión relevante y personalizada. Los filtros disponibles incluyen el año y el mes, el tipo de operación (alquiler o venta), y la selección de distritos y barrios. La combinación de filtros temporales, geográficos y transaccionales permite un número casi ilimitado de análisis de segmentos de mercado específicos.

Esto va más allá de simples comparaciones de distritos; un usuario puede identificar, por ejemplo, las tendencias del mercado de alquiler en un barrio específico durante una temporada particular. Este nivel de granularidad es crucial para la toma de decisiones individuales, ya que las necesidades de vivienda son altamente personales. El cuadro de mando funciona como un escáner de mercado personalizado, permitiendo a los usuarios reducir rápidamente grandes conjuntos de datos a información altamente relevante para sus propósitos específicos.




Ilustración 68 - Alquiler, año 2023, distrito Centro

7.2.2. Análisis Comparativo para una Elección Informada

Para permitir a los usuarios comparar directamente diferentes áreas geográficas o segmentos de mercado, el cuadro de mando también ofrece una funcionalidad específica. Del mismo modo, los usuarios pueden evaluar múltiples opciones simultáneamente, lo que es crucial para permitir la ponderación de alternativas y la toma de decisiones estratégicas. Por este motivo, se incluye una visualización a la que se puede acceder desde el panel “Comparación entre barrios o distritos” otra visualización específica a las necesidades de quienes deben decidir entre opciones de inversión. La interfaz muestra múltiples gráficos de evolución mensual de precios por metro cuadrado para distintos distritos, junto con KPIs comparativos.

La capacidad de comparar directamente dos distritos o barrios en términos de precio, variación y rentabilidad permite a los usuarios cuantificar las diferencias entre posibles opciones. Esto va más allá de simplemente conocer

los precios, permitiendo comprender el valor relativo y el costo de oportunidad de elegir un área sobre otra. Para los inversores, esta característica es crítica para el posicionamiento estratégico, para compradores o inquilinos, ayuda a optimizar su presupuesto y preferencias. El cuadro de mando apoya un proceso de selección más racional y basado en datos, reduciendo la dependencia de la evidencia anecdótica o el sentimiento general del mercado.



Ilustración 69 - Comparativa de 2 distritos (ej. Salamanca vs Usera)

7.2.3. Identificación de Extremos del Mercado y Benchmarking de Rendimiento

Los usuarios pueden identificar rápidamente las áreas con mejor y peor rendimiento según diversas métricas, facilitando una comprensión ágil de los puntos de referencia del mercado y las anomalías. El cuadro de mando incluye "Ranking de precios por m² (distritos y barrios)" y listados de "Top 5 distritos/barrios más caros y baratos", los cuales son claramente visibles en la interfaz. Medidas DAX como Top5VentaBarMasBaratos y Top5VentaBarMasCaros sustentan estas capacidades.

La visualización instantánea de los distritos y barrios con mejor y peor rendimiento permite a los usuarios comprender rápidamente el panorama del mercado e identificar áreas que se desvían significativamente del promedio. Esto no solo se trata de encontrar lo más caro o barato, sino de establecer puntos de referencia. Por ejemplo, si un usuario considera una propiedad en un distrito que no está en el top o bottom 5, puede comparar su precio con los extremos para entender su posición relativa. Esto también ayuda en la detección de anomalías: ¿por qué un barrio en particular es inesperadamente barato o caro? El cuadro de mando proporciona un "chequeo rápido de la salud

del mercado" y resalta áreas que requieren una investigación adicional, ahorrando un tiempo significativo de investigación.



Ilustración 70 - Gráfico tipo barra con Top 5 distritos más caros/baratos

7.3. Información Clave y Análisis Derivables

Esta sección detalla los tipos específicos de información útil y las perspectivas analíticas que pueden extraerse del cuadro de mando sin necesidad de conocimientos técnicos. Se centra en qué revelan los datos sobre el mercado inmobiliario de Madrid y cómo estas revelaciones informan la comprensión del usuario.

7.3.1. Identificación de Tendencias de Precios y Fluctuaciones Estacionales

El cuadro de mando permite a los usuarios observar cómo evolucionan los precios a lo largo del tiempo, detectando tanto tendencias a largo plazo como patrones estacionales a corto plazo. Esta capacidad es crucial para comprender la dinámica del mercado. La visualización de la "Evolución mensual del precio por m²" es útil para identificar tendencias, picos y bajadas. Asimismo, el "Mapa de calor de precios por mes y distrito" permite visualizar

la estacionalidad y detectar los mejores meses para comprar o alquilar. Medidas como variacion_trimestral, variacion_mensual y variacion_anual respaldan directamente esta funcionalidad.

Comprender las tendencias de precios y la estacionalidad no es meramente académico, es altamente estratégico. Para un comprador, identificar un período de precios en descenso o un mes históricamente más barato, como lo muestra el mapa de calor, puede generar ahorros significativos. Para un vendedor, reconocer las temporadas altas puede optimizar el precio de venta. Para los inversores, el momento de entrada y salida es primordial. El cuadro de mando proporciona la base de datos para estas decisiones de tiempo, pasando de una participación reactiva a una proactiva en el mercado. El cuadro de mando sirve como una guía táctica para la participación en el mercado.




Ilustración 71 - Gráfico de evolución mensual del precio por m² 2024

Mapa de Calor de Precios por m² (Mensual por Distrito)												
Distrito	1	2	3	4	5	6	7	8	9	10	11	12
Arganzuela	17,79 €	18,67 €	18,88 €	18,93 €	18,88 €	19,24 €	19,40 €	19,73 €	20,01 €	20,13 €	20,24 €	20,23 €
Barajas			14,74 €	14,86 €	14,80 €	16,90 €	16,34 €	15,84 €	16,34 €	14,48 €	17,01 €	18,17 €
Carabanchel	15,98 €	16,38 €	16,81 €	17,64 €	17,54 €	18,09 €	18,15 €	18,62 €	18,96 €	18,95 €	18,89 €	18,95 €
Centro	22,66 €	23,20 €	23,34 €	23,53 €	23,57 €	23,57 €	23,23 €	23,62 €	23,96 €	24,49 €	24,83 €	25,31 €
Chamartín	19,28 €	19,41 €	19,76 €	20,11 €	20,02 €	20,11 €	20,07 €	20,31 €	20,62 €	20,74 €	20,86 €	21,17 €
Chamberí	21,80 €	22,11 €	22,20 €	22,46 €	22,48 €	22,43 €	22,72 €	22,92 €	23,39 €	23,84 €	23,88 €	23,94 €
Ciudad Lineal	15,77 €	16,19 €	16,37 €	16,79 €	16,90 €	17,17 €	17,13 €	17,10 €	17,30 €	17,20 €	17,26 €	17,47 €
Fuencarral - El Pardo	18,54 €	17,11 €	17,25 €	17,67 €	20,27 €	18,37 €	21,21 €	21,40 €	18,78 €	18,83 €	18,92 €	19,22 €
Hortaleza	17,70 €	21,27 €	21,15 €	21,43 €	21,87 €	22,32 €	22,46 €	22,23 €	22,48 €	22,92 €	22,89 €	23,52 €
Latina	14,42 €	14,94 €	15,05 €	15,01 €	14,86 €	15,14 €	15,43 €	15,88 €	15,98 €	16,53 €	16,81 €	17,23 €
Moncloa - Aravaca	17,06 €	17,40 €	17,42 €	17,64 €	17,81 €	18,14 €	18,18 €	18,24 €	18,26 €	18,69 €	18,45 €	18,76 €
Moratalaz					14,29 €	15,29 €					15,00 €	15,56 €
Puente de Vallecas	14,32 €	14,46 €	14,35 €	14,54 €	14,84 €	14,88 €	14,98 €	15,51 €	15,59 €	15,93 €	15,71 €	16,29 €
Retiro	19,42 €	19,34 €	19,22 €	19,42 €	19,46 €	19,89 €	20,26 €	20,17 €	20,48 €	20,79 €	20,83 €	21,02 €
Salamanca	22,30 €	23,03 €	23,45 €	23,48 €	23,35 €	23,61 €	23,68 €	24,11 €	24,48 €	24,58 €	24,52 €	24,93 €
San Blas - Canillejas	13,33 €	13,86 €	14,72 €	14,69 €	14,53 €	15,23 €	15,28 €	15,20 €	14,88 €	15,22 €	14,82 €	14,82 €
Tetuán	18,46 €	19,24 €	19,49 €	19,69 €	19,88 €	19,94 €	19,64 €	19,92 €	20,29 €	20,48 €	20,37 €	20,64 €
Usera	14,65 €	15,16 €	16,08 €	17,28 €	17,07 €	17,55 €	17,29 €	17,29 €	17,84 €	18,94 €	17,36 €	17,44 €
Vicálvaro	12,83 €	13,18 €	13,18 €	13,00 €	12,96 €	12,95 €	12,71 €	13,44 €	13,45 €	13,43 €	14,19 €	14,26 €
Villa de Vallecas	13,36 €	14,00 €	13,82 €	14,08 €	14,56 €	14,50 €	14,51 €	14,51 €	14,76 €	14,74 €	15,37 €	15,72 €
Villaverde	13,12 €	13,69 €	14,18 €	14,26 €	14,14 €	14,51 €	14,89 €	14,94 €	15,65 €	15,31 €	14,58 €	14,71 €

Ilustración 72 - Mapa de calor temporal 2024

7.3.2. Evaluación de la Rentabilidad y el Riesgo de la Inversión

Los usuarios pueden evaluar el retorno potencial de la inversión y la volatilidad del precio para diferentes áreas, lo que proporciona una dimensión crucial para la toma de decisiones financieras. El cuadro de mando incluye

visualizaciones como la "Comparativa de precio y rentabilidad por zona" y la "Relación entre precio por m² y rentabilidad bruta anual", destacando su utilidad para la evaluación del retorno de la inversión. Crucialmente, la "Relación entre rentabilidad y volatilidad" permite analizar el riesgo (volatilidad del precio) frente a la rentabilidad esperada. Medidas DAX como RentabilidadBruta y VolatilidadPrecio_m2 son la columna vertebral de estas perspectivas.

La capacidad de visualizar la RentabilidadBruta frente a la VolatilidadPrecio_m2 permite a los usuarios realizar un análisis de retorno ajustado al riesgo, rudimentario, pero altamente efectivo. No se trata solo de identificar propiedades "económicas" o con "alta rentabilidad", sino de comprender a fondo la estabilidad del retorno y el riesgo que conlleva. Un usuario puede detectar zonas con buena rentabilidad, pero también con alta volatilidad, lo que implica mayor riesgo, frente a otras más estables, aunque menos rentables. Esta visión financiera más avanzada se vuelve accesible gracias al cuadro de mando, que permite tomar decisiones alineadas con el nivel de riesgo que cada inversor está dispuesto a asumir. El cuadro de mando facilita una estrategia de inversión más madura y matizada, crucial para compromisos financieros significativos como la propiedad.




Ilustración 73 · Gráfico de dispersión: rentabilidad vs volatilidad 2024

7.4. Contribución a la Toma de Decisiones Basadas en Datos

Esta sección aborda directamente cómo el cuadro de mando desarrollado cumple el objetivo central del TFG: ayudar a los usuarios a tomar decisiones informadas sobre la compra o el alquiler de propiedades en Madrid. Articula el valor estratégico derivado de las perspectivas proporcionadas.

7.4.1. Capacitación para Elecciones Inmobiliarias Informadas

El cuadro de mando traduce los datos del mercado inmobiliario en información clara y útil que cualquiera puede aprovechar, permitiendo tomar decisiones importantes sobre vivienda basadas en datos reales y no solo en corazonadas o experiencias aisladas. En este sector, los profesionales suelen contar con herramientas y acceso a los datos que el comprador o inquilino promedio no tiene, generando una desventaja evidente. Al presentar información completa de forma visual y accesible, con filtros y gráficos intuitivos, esta herramienta equilibra ese desequilibrio. Ahora, cualquier persona puede analizar opciones con el mismo nivel de información que los expertos. Esto no solo facilita alcanzar objetivos como comprar o invertir, sino que también hace que el mercado funcione de forma más justa y eficiente para todos.

7.4.2. Mitigación del Riesgo Financiero

Al ofrecer datos sobre la variabilidad de precios, la rentabilidad del alquiler y los valores comparativos del mercado, este panel facilita la detección y gestión de riesgos financieros vinculados a operaciones inmobiliarias. Para este análisis, incorpora la métrica `VolatilidadPrecio_m2` y el gráfico "Relación entre rentabilidad y volatilidad", que permiten evaluar el riesgo con mayor precisión.

Comprar una propiedad suele representar el compromiso financiero más importante en la vida de una persona. Tomar esa decisión sin el respaldo de datos puede hacer que prime la emoción o la información incompleta, lo que aumenta el riesgo de errores costosos o situaciones financieras desfavorables.

Al cuantificar y visualizar explícitamente el riesgo (volatilidad) junto con el retorno potencial (rentabilidad), el cuadro de mando fomenta un proceso de toma de decisiones más prudente y racional. Permite a los usuarios considerar conscientemente la tolerancia al riesgo frente a las ganancias potenciales, lo

que lleva a elecciones más alineadas con sus objetivos financieros y circunstancias personales. Esto apoya directamente el objetivo principal de "ayudar a tomar decisiones basadas en datos" al añadir una capa crítica de prudencia financiera.

7.4.3. Optimización del Proceso de Búsqueda y Selección

La posibilidad de filtrar, comparar y ordenar propiedades o zonas según múltiples criterios hace que el proceso de búsqueda sea mucho más rápido y eficiente, reduciendo tanto el tiempo como el esfuerzo necesario. Entre los filtros disponibles se incluyen año, mes, tipo de operación, así como distrito y barrio, lo que permite afinar los resultados con gran precisión. Los rankings y las vistas comparativas ayudan a reducir las opciones.

Tradicionalmente buscar la propiedad "adecuada" solía requerir una investigación manual exhaustiva, lo que fácilmente podía derivar en exceso de información o en dejar pasar buenas oportunidades. Con el cuadro de mando, que centraliza datos y ofrece filtros y comparaciones intuitivas, el proceso se vuelve mucho más ágil para el usuario. Así, es posible descartar opciones que no se ajustan a los criterios deseados como “alquiler, baja volatilidad, alta rentabilidad en una zona concreta” y centrarse en lo que realmente importa. El resultado: una búsqueda más enfocada, rápida y con decisiones mejor fundamentadas.

7.5. Valor Práctico y Operatividad del Dashboard

Esta sección concluye el documento reafirmando la preparación funcional del cuadro de mando y resumiendo su valor práctico como una herramienta robusta, centrada en el usuario, diseñada para facilitar la comprensión del mercado inmobiliario de Madrid.

7.5.1. Aplicabilidad en el Mundo Real para Diversos Usuarios

El diseño y las funcionalidades del cuadro de mando lo hacen útil para un público amplio, desde compradores y arrendatarios particulares hasta pequeños inversores o profesionales del sector que requieran información de mercado rápida y eficaz. Tal como se explica en la Sección 6.5, se ha puesto especial atención en facilitar su uso incluso para personas sin formación técnica.

Pese a ser un desarrollo realizado en el contexto de un Trabajo de Fin de Grado, su enfoque en la usabilidad y la entrega de información práctica le otorgan una clara aplicabilidad fuera del entorno académico. No es solo una

prueba de concepto, sino una herramienta funcional, capaz de asistir eficazmente a distintos perfiles de usuario. Este planteamiento permite vislumbrar un impacto escalable, con posibilidades reales de aplicación en ámbitos comerciales o como servicio público, generando así un valor concreto para la comunidad destinataria.

7.6. Funcionalidad adicional: Calculadora de rentabilidad (versión beta)

Finalmente, como una funcionalidad adicional, el dashboard incluye una calculadora de rentabilidad inmobiliaria que se puede encontrar en un botón en la parte superior derecha. Aunque todavía está en una versión temprana, la finalidad es clara: permitir al usuario simular la viabilidad financiera de una inversión en vivienda usando datos personalizados.

Aunque esta calculadora no constituye el objetivo principal del proyecto, su creación surge como una extensión lógica de la plataforma. Se diseñó pensando en algo que mucha gente necesita: conocer de forma rápida y sencilla si una propiedad resulta rentable en función de determinados parámetros.

Está organizada para guiar al usuario paso a paso por las diferentes etapas de una inversión inmobiliaria, desde la compra hasta calcular ingresos y gastos, y al final, obtener la rentabilidad. Esto permite al usuario comprender el impacto de cada variable en el resultado final, facilitando un análisis financiero detallado y personalizado.

La herramienta deja que el usuario ingrese manualmente los datos clave en campos que se resaltan en color celeste. Una vez que ingresas esos datos, la calculadora hace el trabajo pesado y calcula automáticamente algunos indicadores económicos clave.

Secciones de la Calculadora de Rentabilidad:

Precio Entrada Total:

Esta sección está diseñada para capturar todos los costes iniciales asociados a la adquisición de una propiedad, más allá del precio de compraventa. Su objetivo es proporcionar una visión realista de la inversión total requerida.

- **Vivienda:** Muestra el precio total de la propiedad.

- **Compraventa:** Campo de entrada para el precio de compra del inmueble. Este es el coste base del activo.
- **ITP en Comunidad de Madrid:** Muestra el porcentaje del Impuesto de Transmisiones Patrimoniales, un tributo autonómico que se aplica a la compraventa de bienes inmuebles de segunda mano, con una tasa general del 6% en Madrid.
- **ITP a pagar:** Campo calculado que muestra el importe del ITP.
- **Notaría (de la compraventa):** Campo de entrada para los honorarios del notario por su intervención en la compraventa de una vivienda.
- **Registro (de la compraventa):** Campo de entrada para los gastos de inscripción de la vivienda en el Registro de la Propiedad.
- **Reforma:** Campo de entrada para los costes de conservación y reparación necesarios para mantener el uso normal del inmueble.
- **Comisión Agencia:** Campo de entrada para los honorarios que una agencia cobra por gestionar la compraventa del inmueble.
- **Gastos Hipoteca:** Muestra el total de los gastos asociados a la obtención de la hipoteca.
- **Gestoría:** Campo de entrada para los gastos preparatorios del préstamo hipotecario, relacionados con los trámites de las escrituras hasta su inscripción en el Registro de la Propiedad.
- **Tasación:** Campo de entrada para la valoración profesional imparcial del valor justo de mercado de la vivienda.
- **Comisión de apertura:** Campo de entrada para el gasto que se suma al importe del préstamo hipotecario por los costes en los que incurre la entidad por tramitar el préstamo.

Alquiler:

Esta sección se centra en la estimación de los ingresos que la propiedad generaría a través del alquiler.

- **Renta Mensual:** Campo de entrada para el pago mensual que se espera recibir por el alquiler de la propiedad.
- **Renta Anual:** Campo calculado que muestra el importe total de la renta anual.

Estimación Gastos Anuales:

Esta sección permite al usuario introducir los gastos recurrentes asociados a la propiedad, esenciales para calcular la rentabilidad neta.

- **Comunidad año:** Campo de entrada para los gastos anuales destinados al mantenimiento ordinario o extraordinario del edificio.
- **Mantenimiento:** Campo de entrada para los costes esenciales para conservar la propiedad en buen estado y garantizar su funcionalidad a largo plazo.
- **Seguro Hogar:** Campo de entrada para el contrato que cubre los daños materiales causados en la vivienda y los bienes en ella.
- **Seguro Vida Hipoteca:** Campo de entrada para la herramienta que protege a la familia del titular de posibles deudas tras su fallecimiento.
- **Seguro Impago:** Campo de entrada para la solución que protege a los propietarios frente a posibles incumplimientos de pago del alquiler.
- **IBI:** Campo de entrada para el Impuesto sobre Bienes Inmuebles, un impuesto directo municipal que grava el valor de los bienes inmuebles.
- **Sum Intereses Hipoteca (Año 1):** Campo de entrada para el coste que se genera sobre el capital invertido en el primer año de hipoteca.
- **Períodos Vacantes:** Campo de entrada para el tiempo durante el cual una propiedad de alquiler estuvo desocupada.
- **Total:** Campo calculado que muestra la suma de todos los gastos anuales estimados.

Financiación:

Esta sección permite modelar las condiciones de la hipoteca, crucial para entender la estructura de la inversión y el impacto de la deuda.

- **% financiado sobre compra:** Campo de entrada para el porcentaje del precio de compra que se financiará mediante hipoteca.
- **Préstamo hipotecario:** Campo calculado que muestra el importe del préstamo a medio o largo plazo otorgado para la compra de la vivienda.

- **Capital propio:** Campo calculado que muestra la inversión de capital o deuda con garantía inmobiliaria aportado por el usuario.
- **Interés Mensual:** Campo de entrada para el coste de prestar el dinero de la hipoteca, que forma parte del pago mensual.
- **Plazos:** Campo de entrada para la duración del préstamo, o la cantidad de tiempo que le llevará al prestatario pagar el total del préstamo.
- **Cuota anual:** Campo calculado que muestra el pago mensual que el titular de una hipoteca realiza para amortizar la deuda y pagar los intereses asociados.
- **Parte Intereses:** Campo calculado que muestra la porción de intereses del pago anual de la hipoteca.
- **Parte Devolución:** Campo calculado que muestra la porción de capital (dinero prestado) que se devuelve anualmente.

Beneficio (antes de impuestos):

Esta sección permite estimar el beneficio de la inversión considerando la situación fiscal del usuario.

- **Salario Bruto Anual:** Campo de entrada para la retribución total que percibe una persona trabajadora durante un año de trabajo antes de deducciones.
- **Tramo IRPF (%):** Campo de entrada para el tipo impositivo a aplicar según el rango de ingresos para el cálculo del Impuesto sobre la Renta de las Personas Físicas.
- **Amortización anual:** Campo calculado que muestra la amortización anual del capital.
- **Impuestos (Aprox):** Campo calculado que estima los impuestos a los que está sujeta la inversión inmobiliaria.
- **Beneficio (después de impuestos):** Campo calculado que muestra el beneficio obtenido después de deducir todos los gastos registrados, incluyendo los impuestos.

Rentabilidad y Ratio:

Esta sección presenta los indicadores clave de rendimiento de la inversión, proporcionando una evaluación concisa de su viabilidad.

- **Rentabilidad Bruta (%):** Campo calculado que muestra el porcentaje de beneficio obtenido de una inversión en un inmueble.
- **Rentabilidad Neta (%):** Campo calculado que mide la rentabilidad más precisa y realista, dividiendo los ingresos anuales menos los gastos, entre el precio de compra de la propiedad, y multiplicando por 100.
- **Cashflow Anual (después de Pago Deuda):** Campo calculado que muestra la liquidez anual que genera un inmueble alquilado después de cubrir todos los costes operativos necesarios.
- **ROCE (Return on Capital Employed):** Campo calculado que compara una métrica de beneficio con la cantidad de capital empleado, indicando cuánto beneficio genera la empresa por cada euro de capital empleado.

Tabla 7 - Tabla de Entradas y Salidas de la Calculadora de Rentabilidad

Tipo	Nombre del Campo	Descripción
Entrada	Compraventa	Precio de adquisición del inmueble.
Entrada	Notaría (de la compraventa)	Coste de los servicios notariales para la compraventa.
Entrada	Registro (de la compraventa)	Coste de inscripción de la propiedad en el registro.
Entrada	Reforma	Coste estimado de las reformas o mejoras necesarias.
Entrada	Comisión Agencia	Honorarios pagados a la agencia inmobiliaria.
Entrada	Gestoría	Coste de los servicios de gestoría para la hipoteca.
Entrada	Tasación	Coste de la valoración oficial del inmueble.
Entrada	Comisión de apertura	Comisión cobrada por el banco al formalizar la hipoteca.
Entrada	Renta Mensual	Ingreso mensual esperado por el alquiler.

Entrada	Comunidad año	Gasto anual de la comunidad de propietarios.
Entrada	Mantenimiento	Gasto anual estimado en mantenimiento y reparaciones.
Entrada	Seguro Hogar	Coste anual del seguro de hogar.
Entrada	Seguro Vida Hipoteca	Coste anual del seguro de vida asociado a la hipoteca.
Entrada	Seguro Impago	Coste anual del seguro de impago de alquiler.
Entrada	IBI	Impuesto anual sobre Bienes Inmuebles.
Entrada	Sum Intereses Hipoteca (Año 1)	Suma de intereses de la hipoteca durante el primer año.
Entrada	Períodos Vacantes	Días o porcentaje de tiempo que la propiedad podría estar desocupada.
Entrada	Salario Bruto Anual	Salario bruto anual del inversor para cálculo fiscal.
Entrada	Tramo IRPF (%)	Porcentaje del tramo de IRPF aplicable al inversor.
Entrada	% financiado s/compra	Porcentaje del precio de compra financiado por hipoteca.
Entrada	Interés Mensual	Tipo de interés mensual de la hipoteca.
Entrada	Plazos (años) (max 40)	Plazos de amortización de la hipoteca en años.
Salida	Precio Entrada Total	Suma de la compraventa y los gastos iniciales.
Salida	ITP a pagar	Importe calculado del Impuesto de Transmisiones Patrimoniales.
Salida	Gastos Hipoteca	Suma de los gastos asociados a la hipoteca.

Salida	Renta Anual	Renta mensual multiplicada por 12.
Salida	Total (Gastos Anuales)	Suma de todos los gastos anuales estimados.
Salida	Préstamo hipotecario	Importe total del préstamo hipotecario.
Salida	Capital propio	Capital aportado por el inversor (Precio Entrada Total - Préstamo hipotecario).
Salida	Cuota anual	Pago anual total de la hipoteca.
Salida	Parte Intereses	Parte de la cuota anual destinada al pago de intereses.
Salida	Parte Devolución	Parte de la cuota anual destinada a la amortización del capital.
Salida	Beneficio (antes de impuestos)	Beneficio de la inversión antes de aplicar impuestos.
Salida	Amortización anual	Amortización anual del capital del préstamo.
Salida	Impuestos (Aprox)	Estimación de los impuestos a pagar sobre el beneficio.
Salida	Beneficio (después de impuestos)	Beneficio final de la inversión tras deducir impuestos.
Salida	Rentabilidad Bruta (%)	Rentabilidad de la inversión antes de gastos detallados.
Salida	Rentabilidad Neta (%)	Rentabilidad de la inversión después de todos los gastos.
Salida	Cashflow Anual (después de Pago Deuda)	Flujo de efectivo anual generado por la inversión.
Salida	ROCE (Return on Capital Employed)	Eficiencia con la que el capital empleado genera beneficios.

Esta primera versión tiene un enfoque funcional básico y puede considerarse una fase inicial o "versión beta", sin pretensiones de ofrecer un cálculo financiero exhaustivo.

Sin embargo, su inclusión permite visualizar el potencial del sistema como herramienta de ayuda a la inversión inmobiliaria personalizada. Asimismo, abre la puerta a futuras líneas de desarrollo donde esta funcionalidad podría enriquecerse con valores por defecto vinculados a zonas específicas (obtenidos del propio DataMart), incorporación de escenarios comparativos o ajustes más detallados en función del perfil de riesgo del usuario.

En conjunto, esta funcionalidad representa un primer paso hacia un sistema integral de asesoramiento basado en datos abiertos. Aunque en fase preliminar, anticipa futuras evoluciones del proyecto, con mayor automatización, incorporación de datos históricos del DataMart o personalización según perfiles de riesgo.

Calculadora de Rentabilidad

Rellenar los campos en azul

Precio Entrada Total :	263,50 mil	Alquiler	
Vivienda	256,80 mil	Renta Mensual :	5000
Compraventa :	230.000,00 €	Renta Anual :	60,00 mil
Estimación Gastos Anuales			
ITP en Comunidad de Madrid :	6%	Comunidad año :	5000
ITP a pagar :	13,80 mil	Mantenimiento :	5000
Notaría (de la compraventa) :	1000	Seguro Hogar :	5000
Registro (de la compraventa)	1000	Seguro Vida Hipoteca :	5000
Reforma :	1000	Seguro Impago :	5000
Comisión Agencia :	10000	IBI :	3000
Gastos Hipoteca :	6,70 mil	Sum Intereses hipoteca (Año1) :	2.028 €
Gestoría :	100	Periodos Vacantes :	5000
Tasación :	1000	Total :	35,03 mil
Comisión de apertura :	5600	Beneficio (antes de impuestos) :	24,97 mil
Financiación		Salario Bruto Anual :	70000
%financiado s/compra :	100	Tramo IRPF (%) :	45
Préstamo hipotecario:	230,00 mil	Amortización anual :	2,49 mil
Capital propio:	33,50 mil	Impuestos (Aprox) :	5,06 mil
Condiciones de hipoteca:		Beneficio (después de impuestos) :	19,91 mil
Interés Mensual:	0,08		
Plazo (años) (max 40):	30		
Cuota anual :	8.827 €		
Parte Intereses :	2.028 €		
Parte Devolución :	6.799 €		

Tramo IRPF

0€ - 12.450€ :	19%
12.450€ - 20.200€ :	24%
20.200€ - 35.200€ :	30%
35.200€ - 60.000€ :	37%
Más de 60.000€ :	45%

Rentabilidad y Ratio

	Prudente	Optimista
Rentabilidad Bruta (%)	22,77	22,77
Rentabilidad Neta (%)	7,56	11,35
Cashflow Anual (después de Pago Deuda)	13,11 mil€	23,11 mil€
ROCE (Return on Capital Employed)	39,15%	69,00%

Ilustración 74 - Calculadora de Rentabilidad (versión beta)

8. Impacto Socioambiental

El propósito de la siguiente sección es realizar una evaluación completa del impacto ambiental asociado al desarrollo del TFG. Este trabajo se basa en la elaboración de una herramienta de visualización de datos abiertos, con la finalidad de simplificar el trabajo de análisis del mercado inmobiliario dentro de la ciudad de Madrid. La herramienta fue desarrollada mediante Power BI y datos públicos.

A lo largo de este informe se analizarán tanto los impactos directos como indirectos del proyecto para el medio ambiente, centrándose especialmente en el consumo de recursos, las emisiones, y la contribución a la sostenibilidad urbana y digital.

8.1. Naturaleza del Proyecto y su Impacto Ambiental Directo

El proyecto se inscribe dentro de la disciplina de la ingeniería del software, con una orientación específica hacia el análisis de datos y la representación visual de la información. Su ejecución no implica la puesta en marcha de procesos industriales, la fabricación de productos tangibles, ni la creación de software destinado a un uso intensivo de recursos energéticos durante su funcionamiento.

El resultado primordial del proyecto es un panel de control digital, cuyo consumo energético se circunscribe al período de utilización activa por parte del usuario final. La actividad fundamental reside en la manipulación, el procesamiento y la representación de datos preexistentes, lo que conlleva un impacto ambiental directo intrínsecamente nulo o muy reducido.

8.2. Consumo de recursos del software utilizado

El principal software utilizado para la presentación de datos es Power BI, una herramienta de inteligencia empresarial proporcionada por Microsoft. Power BI es un software convencional de escritorio y portátil que se encuentra dentro del rango de uso común en entornos académicos y profesionales. Power BI se centra en el manejo de datos y la usabilidad: compresión de datos, recuperación rápida de datos, etc., en lugar de la simulación de procesos intensivos en el uso de recursos o programas de diseño. En ese sentido, no consume energía excesivamente ni genera emisiones relacionadas con la demanda de energía del uso de esta herramienta.

8.3. Uso de Hardware e Infraestructura

El proyecto se desarrolla en equipos informáticos estándar, sin necesidad de hardware especializado como servidores de alto rendimiento o infraestructuras de refrigeración avanzadas. Esto se alinea con los entornos típicos de desarrollo académico.

Además, el proyecto se apoya en infraestructuras existentes, accediendo a los datos a través de internet desde fuentes públicas. No se requiere la creación ni el mantenimiento de infraestructura tecnológica propia, lo cual minimiza el impacto ambiental asociado al despliegue de nuevas instalaciones.

Esta dependencia de sistemas ya operativos asegura que la huella de carbono del proyecto se mantenga en niveles mínimos, especialmente en comparación con iniciativas que requieren equipamiento o centros de datos de gran escala.

8.4. Sostenibilidad Digital

El TFG promueve activamente la sostenibilidad digital, entendida como el uso eficiente y responsable de las tecnologías digitales. Una de sus principales fortalezas es el uso de datos abiertos, accesibles de forma gratuita y reutilizable, lo cual elimina la necesidad de recopilar información desde cero y evita el consumo de recursos adicionales.

La reutilización de información ya disponible reduce esfuerzos redundantes, disminuye la huella ambiental y fomenta la transparencia y la innovación. Este planteamiento se alinea con los principios de una economía circular de los datos, donde el valor se maximiza mediante la reutilización continua.

Plataformas como el Portal de Datos Abiertos del Ayuntamiento de Madrid, el INE o Idealista son fundamentales para esta estrategia, ya que proporcionan datos estructurados que permiten desarrollar herramientas como este cuadro de mando sin incurrir en costes energéticos innecesarios.

Asimismo, el aprovechamiento de la infraestructura digital ya existente evita el despliegue de nuevos recursos, lo que refuerza la eficiencia energética y reduce el impacto ambiental del proyecto, alineándose plenamente con los principios de sostenibilidad tecnológica.

8.5. Contribución Indirecta a Modelos Urbanos Sostenibles

Junto con su impacto directo en el medio ambiente, el proyecto tiene un posible beneficio ambiental indirecto. Los datos extraídos y los análisis registrados en la herramienta también son críticos para tomar decisiones razonables en proyectos urbanísticos futuros.

La herramienta desarrollada permite analizar tendencias de precios, superficie media y evolución histórica del mercado inmobiliario, lo cual puede ser crucial para diseñar políticas de vivienda, planes de zonificación o estrategias de rehabilitación urbana. De este modo, el proyecto proporciona una base empírica para fomentar modelos urbanos más sostenibles.

Por ejemplo, tener evidencia sobre áreas con alta demanda de vivienda y disponibilidad limitada les permite decidir sobre zonificación, densificación equilibrada o restricciones al desarrollo a largo plazo. Esta capacidad de análisis contribuye también a una asignación más equitativa de los recursos urbanos y a una mejor comprensión de la dinámica habitacional.

Al mismo tiempo, también permite una planificación eficiente, justa y sostenible, lo que le da un valor agregado en términos de sostenibilidad en el tiempo.

En definitiva, el presente TFG se caracteriza por tener un impacto ambiental directo nulo o muy bajo, gracias a su enfoque informático, el uso de herramientas eficientes y la reutilización de datos abiertos. Su alineación con la sostenibilidad digital y su potencial para apoyar decisiones urbanísticas responsables refuerzan su carácter respetuoso con el medio ambiente. De este modo, el proyecto no solo cumple con los criterios técnicos y académicos propios de su disciplina, sino que también contribuye activamente a los principios de sostenibilidad y eficiencia en el uso de recursos tecnológicos.

9. Conclusiones

9.1. Revisión de las Aportaciones del Trabajo

En definitiva, este Trabajo de Fin de Grado ha hecho posible la creación de un cuadro de mando interactivo en Power BI, orientado a analizar el mercado inmobiliario en la ciudad de Madrid. Desde el principio, se manejó con un enfoque muy detallado, considerando la importancia de cada aspecto: la estructuración del modelo de datos y la tarea de diseñar visualizaciones, todo esto orientado a ofrecer un conjunto de herramientas que proporcionan un beneficio real y concreto para el usuario final.

El resultado es una herramienta visualmente clara, funcional y fácil de usar que permite comparar rápidamente entre barrios y distritos, analizar la evolución de precios, rentabilidad y otros indicadores clave en un marco intuitivo. Con filtros interactivos, KPIs, mapas y gráficos dinámicos, permitiendo que, incluso personas con poca experiencia técnica en el campo pueden extraer sus conclusiones de interés y tomar decisiones más informadas.

Por otro lado, se ha hecho un uso intensivo del lenguaje DAX para resolver cálculos complejos, como diferencias temporales, métricas condicionadas por múltiples filtros o comparaciones geográficas. Esta capa analítica ha aportado un nivel de profundidad que transforma el cuadro de mando en mucho más que una simple visualización: lo convierte en una auténtica herramienta de apoyo inteligente para la toma de decisiones.

9.2. Aprendizajes Clave e Hitos del Desarrollo

A lo largo del desarrollo, uno de los mayores aprendizajes ha sido entender que la clave del valor en un producto de inteligencia de negocio no reside únicamente en los datos, sino en cómo se presentan y en la experiencia del usuario al interactuar con ellos. Este principio ha guiado la elección de cada visualización, la disposición de los elementos y la claridad de las leyendas y tooltips.

También se ha demostrado la importancia de mantener una arquitectura de datos eficiente y bien estructurada. Desde la definición inicial del modelo estrella hasta la implementación de medidas y relaciones en Power BI, el

proyecto ha seguido buenas prácticas que aseguran escalabilidad y mantenibilidad en el tiempo.

Otro hito relevante ha sido lograr un diseño que integra tanto el análisis exploratorio como el comparativo, permitiendo a los usuarios navegar entre zonas, visualizar cambios en el tiempo y descubrir patrones de comportamiento del mercado inmobiliario con facilidad.

9.3. Vías de Continuación

El trabajo sienta una base sólida sobre la cual se podrían desarrollar nuevas funcionalidades. Entre las mejoras futuras más relevantes se encuentra la posibilidad de añadir series temporales más largas, incorporar variables macroeconómicas (como tipos de interés o IPC) y ampliar el análisis a otras regiones fuera de Madrid.

También se podrían integrar datos en tiempo real desde APIs inmobiliarias para que la herramienta no solo sirva como análisis histórico, sino también como visor de ofertas actuales. De igual forma, podría explorarse la integración con modelos predictivos más complejos, entrenados con aprendizaje automático, para estimar precios o rentabilidades futuras con mayor precisión.

Además, como funcionalidad adicional ya en fase beta, se contempla la mejora y ampliación de una calculadora de rentabilidad inmobiliaria, que permitirá a los usuarios simular la viabilidad financiera de inversiones personalizadas, facilitando un análisis detallado del impacto económico según distintos parámetros.

Finalmente, desde el punto de vista del usuario, sería interesante ofrecer una versión web interactiva fuera del entorno de Power BI, que amplíe el acceso a personas sin cuenta profesional, facilitando aún más su adopción.

9.4. Reflexión Final Personal

En resumen, este proyecto ha sido un desafío técnico acompañado de un gran crecimiento personal. Por un lado, me ha dado la posibilidad de implementar de manera concreta todo el conocimiento académico acumulado a lo largo de mi carrera, desde los fundamentos del modelado de datos hasta la visualización y el diseño centrado en el usuario. Pero, mucho más allá de lo

técnico, me ha enseñado a abordar problemas concretos con respuestas efectivas, siempre manteniendo la mirada en el punto de impacto real.

El resultado final no solo responde a los objetivos iniciales, sino que también deja espacio para nuevas ideas, preguntas y posibles líneas de trabajo. Siento que he conseguido transformar un conjunto de datos en una herramienta clara, funcional y con margen para seguir evolucionando. Este proceso de construir, revisar y mejorar ha sido profundamente enriquecedor, y sin duda, marca un punto de inflexión en mi camino como futuro ingeniero del software.

10. Referencias

- Microsoft. (2023). *Power BI documentation*. <https://docs.microsoft.com/en-us/power-bi/>
- Tufte, E. R. (2001). *The visual display of quantitative information* (2nd ed.). Graphics Press.
- Hakoit. (s.f.). *¿Qué es Power BI?*. [Artículo web]. <https://www.hakoit.com/que-es-power-bi/>
- Microsoft. (s.f.). *Información general de Power BI*. <https://learn.microsoft.com/es-es/power-bi/fundamentals/power-bi-overview>
- KNIME AG. (s.f.). *KNIME Analytics Platform*. Recuperado de <https://www.knime.com/knime-analytics-platform>
- Ayuntamiento de Madrid. (s. f.). *Superficie media (m²) de las viviendas por Distrito y Barrio según Tipo*. <https://www.madrid.es/portales/munimadrid/es/Inicio/El-Ayuntamiento/Estadistica/Areas-de-informacion-estadistica/Edificacion-y-vivienda/Mercado-de-la-vivienda/Compra-venta-de-viviendas/?vgnextfmt=default&vgnextoid=9b8db9602f841510VgnVCM1000000b205a0aRCRD&vgnnextchannel=22613c7ea422a210VgnVCM1000000b205a0aRCRD>
- Ayuntamiento de Madrid. (s. f.). *Distritos municipales de Madrid*. <https://datos.madrid.es/portal/site/egob/menuitem.c05c1f754a33a9fbe4b2e4b284f1a5a0/?vgnextoid=7d6e5eb0d73a7710VgnVCM2000001f4a900aRCRD&vgnnextchannel=374512b9ace9f310VgnVCM100000171f5a0aRCRD&vgnextfmt=default>
- Ayuntamiento de Madrid. (s. f.). *Barrios municipales de Madrid*. <https://datos.madrid.es/portal/site/egob/menuitem.c05c1f754a33a9fbe4b2e4b284f1a5a0/?vgnextoid=760e5eb0d73a7710VgnVCM2000001f4a900aRCRD&vgnnextchannel=374512b9ace9f310VgnVCM100000171f5a0aRCRD&vgnextfmt=default>
- Ayuntamiento de Madrid. (s. f.). *Evolución del precio de alquiler de la vivienda (€/m²) por Distrito y Barrio*. https://servpub.madrid.es/CSEBD_WBINTER/seleccionSerie.html?numSerie=0504030000214
- Ayuntamiento de Madrid. (s. f.). *Evolución del precio de venta de la vivienda (€/m²) por Distrito y Barrio*. https://servpub.madrid.es/CSEBD_WBINTER/seleccionSerie.html?numSerie=0504030000153
- Instituto Nacional de Estadística. (s. f.). *Índice de Precios de Vivienda (IPV)*. https://www.ine.es/dyngs/INEbase/operacion.htm?c=Estadistica_C&cid=1254736152838&menu=ultiDatos&idp=1254735976607

Instituto Nacional de Estadística. (s. f.). *Índice de Precios de Vivienda en Alquiler (IPVA)*.
https://www.ine.es/dyngs/INEbase/operacion.htm?c=Estadistica_C&cid=1254736176802&menu=ultiDatos&idp=1254735976607

Instituto Nacional de Estadística. (s. f.). *Índice de Precios al Consumo (IPC)*.
https://www.ine.es/dyngs/INEbase/operacion.htm?c=Estadistica_C&cid=1254736176802&menu=ultiDatos&idp=1254735976607

EpData. (s. f.). *Salario medio anual en la Comunidad de Madrid*.
<https://www.epdata.es/salario-medio-anual-comunidad/97b8cd56-8314-4891-b043-7b57606666ff/madrid/304>

Ayuntamiento de Madrid. (s. f.). *Hipoteca media (€). Tipo de interés medio. Cuota hipotecaria mensual media a 20 años y al plazo contratado (€) por Distrito y Barrio*.
https://servpub.madrid.es/CSEBD_WBINTER/seleccionSerie.html?numSerie=0504020100150

Kimball, R., & Ross, M. (2013). *The data warehouse toolkit: The definitive guide to dimensional modeling*. John Wiley & Sons.

Inmon, W. H. (2005). *Building the data warehouse*. John Wiley & Sons.

Domoblock. (s.f.). *Rentabilidad Inmobiliaria: Qué es y Cómo se calcula*. Recuperado de <https://www.domoblock.io/blog/rentabilidad-inmobiliaria-que-es-y-como-se-calcula>

Prinex. (s.f.). *¿Cómo calcular rentabilidad inversión inmobiliaria?*. Recuperado de <https://prinex.com/rentabilidad-inversion-inmobiliaria/>

GoCardless. (s.f.). *Return on Capital Employed (ROCE) | Formula + Calculator*. Recuperado de <https://gocardless.com/en-us/guides/posts/formula-return-on-capital-employed/>

Todas las referencias bibliográficas fueron consultadas entre febrero y mayo de 2025.

11. Anexos

Anexo A. Script Python en KNIME para el cálculo de variaciones temporales (mensual, trimestral y anual):

```

1 import pandas as pd
2 import numpy as np
3
4 df = input_table_1.copy()
5
6 # Better conversion of ColumnValues with detailed cleaning
7 df['ColumnValues'] = df['ColumnValues'].astype(str)
8 # Remove any whitespace and replace various decimal separators
9 df['ColumnValues'] = df['ColumnValues'].str.strip().str.replace(',', '.').str.replace(' ', '')
10 # Convert to float with better error handling
11 df['ColumnValues'] = pd.to_numeric(df['ColumnValues'], errors='coerce')
12
13 # Convert id_tiempo to format numérico
14 df['id_tiempo'] = pd.to_numeric(df['id_tiempo'], errors='coerce')
15
16 # Ordenar por distrito, barrio y tiempo para calcular correctamente las variaciones
17 df = df.sort_values(['cod_distrito', 'cod_barrio', 'id_tiempo'])
18
19 # Crear las nuevas columnas con valores iniciales NaN
20 df['variacion_mensual'] = np.nan
21 df['variacion_trimestral'] = np.nan
22 df['variacion_anual'] = np.nan
23
24 # Agrupar por distrito y barrio para calcular las variaciones dentro de cada grupo
25 for (distrito, barrio), group in df.groupby(['cod_distrito', 'cod_barrio']):
26     # Convert to DataFrame to ensure we have a copy
27     group_df = pd.DataFrame(group).sort_values('id_tiempo')
28
29     # Calcular variación mensual (respecto al mes anterior)
30     group_df['variacion_mensual'] = (group_df['ColumnValues'].pct_change() * 100).round(1)
31
32     # Calcular variación trimestral (respecto a 3 meses antes)
33     group_df['variacion_trimestral'] = (group_df['ColumnValues'].pct_change( periods=3 ) * 100).round(1)
34
35     # Calcular variación anual (respecto a 12 meses antes)
36     group_df['variacion_anual'] = (group_df['ColumnValues'].pct_change( periods=12 ) * 100).round(1)
37
38     # Actualizar los valores en el dataframe original
39     df.loc[(df['cod_distrito'] == distrito) & (df['cod_barrio'] == barrio), 'variacion_mensual'] = group_df['variacion_mensual'].values
40     df.loc[(df['cod_distrito'] == distrito) & (df['cod_barrio'] == barrio), 'variacion_trimestral'] = group_df['variacion_trimestral'].values
41     df.loc[(df['cod_distrito'] == distrito) & (df['cod_barrio'] == barrio), 'variacion_anual'] = group_df['variacion_anual'].values
42
43 # Reemplazar el dataframe original con el nuevo que tiene las columnas adicionales
44 output_table_1 = df

```

Ilustración 75 - Script para obtener las variaciones temporales

Anexo B. Script Python en KNIME para el cálculo del precio estimado de vivienda y otras métricas derivadas:

```

1 # Usar los dataframes existentes
2 df_alquiler = input_table_1.copy() # Tabla principal de alquileres
3 df_distrito = input_table_2.copy() # Tabla dim_distrito
4 df_barrio = input_table_3.copy() # Tabla dim_barrio
5
6 import pandas as pd
7 import numpy as np
8
9 # Verificar las columnas en cada DataFrame
10 print("Columnas en df_alquiler:", df_alquiler.columns.tolist())
11 print("Columnas en df_distrito:", df_distrito.columns.tolist())
12 print("Columnas en df_barrio:", df_barrio.columns.tolist())
13
14 # Renombrar ColumnValues a precio_m2
15 df_resultado = df_alquiler.copy()
16 df_resultado.rename(columns={'ColumnValues': 'precio_m2'}, inplace=True)
17
18 # Asegurar que los tipos son strings para los joins
19 df_resultado['cod_distrito'] = df_resultado['cod_distrito'].astype(str)
20 df_resultado['cod_barrio'] = df_resultado['cod_barrio'].astype(str)
21 df_distrito['cod_distrito'] = df_distrito['cod_distrito'].astype(str)
22 df_barrio['cod_barrio'] = df_barrio['cod_barrio'].astype(str)
23
24 # Unir con dim_distrito
25 print("Antes del join con distrito, filas:", len(df_resultado))
26 df_resultado = pd.merge(
27     df_resultado,
28     df_distrito[['cod_distrito', 'id_distrito', 'superficie_media_vivienda']],
29     on='cod_distrito',
30     how='left'
31 )
32 print("Después del join con distrito, filas:", len(df_resultado))
33
34 # Unir con dim_barrio
35 print("Antes del join con barrio, filas:", len(df_resultado))
36 df_resultado = pd.merge(
37     df_resultado,
38     df_barrio[['cod_barrio', 'id_barrio', 'superficie_media_vivienda']],
39     on='cod_barrio',
40     how='left',
41     suffixes=('_distrito', '_barrio')
42 )
43 print("Después del join con barrio, filas:", len(df_resultado))
44
45 # Verificar columnas después de los joins
46 print("Columnas después de los joins:", df_resultado.columns.tolist())
47
48 # Determinar la superficie media correcta
49 df_resultado['superficie_media'] = df_resultado.apply(
50     lambda row: row['superficie_media_vivienda_distrito'] if row['cod_barrio'] == '000'
51     else row['superficie_media_vivienda_barrio'],
52     axis=1
53 )
54
55 # CAMBIO: Convertir valores 0 a None (no NaN)
56 df_resultado['superficie_media'] = df_resultado['superficie_media'].replace(0, None)
57
58 # Convertir a float explícitamente para asegurar compatibilidad
59 df_resultado['precio_m2'] = pd.to_numeric(df_resultado['precio_m2'], errors='coerce')
60 df_resultado['superficie_media'] = pd.to_numeric(df_resultado['superficie_media'], errors='coerce')
61
62 # Reemplazar NaN con None después de las conversiones numéricas
63 df_resultado['precio_m2'] = df_resultado['precio_m2'].where(pd.notna(df_resultado['precio_m2']), None)
64 df_resultado['superficie_media'] = df_resultado['superficie_media'].where(pd.notna(df_resultado['superficie_media']), None)
65
66 # Calcular precio promedio de vivienda solo para filas con superficie válida
67 df_resultado['precio_promedio_vivienda'] = df_resultado['precio_m2'] * df_resultado['superficie_media']
68
69 # Ingresos anuales (renombrado a total_anual como solicitado)
70 df_resultado['total_anual'] = df_resultado['precio_promedio_vivienda'] * 12
71
72 # CAMBIO: Asegurar que 0 se convierta en None para todas las columnas relevantes
73 df_resultado['superficie_media'] = df_resultado['superficie_media'].replace(0, None)
74 df_resultado['precio_promedio_vivienda'] = df_resultado['precio_promedio_vivienda'].replace(0, None)
75 df_resultado['total_anual'] = df_resultado['total_anual'].replace(0, None)
76
77 # Reemplazar cualquier NaN que pudiera haberse generado con None
78 df_resultado = df_resultado.replace({np.nan: None})
79
80 # Redondear estos valores para mejor presentación (solo los valores no-None)
81 df_resultado['precio_promedio_vivienda'] = df_resultado.apply(
82     lambda row: round(row['precio_promedio_vivienda'], 2) if row['precio_promedio_vivienda'] is not None else None,
83     axis=1
84 )
85 df_resultado['total_anual'] = df_resultado.apply(
86     lambda row: round(row['total_anual'], 2) if row['total_anual'] is not None else None,
87     axis=1
88 )
89
90 # Seleccionar las columnas finales OMITIENDO las columnas problemáticas
91 columnas_finales = [
92     'id_tiempo', 'id_barrio', 'id_distrito', 'tipo_operacion',
93     'precio_m2', 'variacion_mensual', 'variacion_trimestral', 'variacion_anual',
94     'superficie_media', 'precio_promedio_vivienda', 'total_anual'
95     # Se eliminan: 'rentabilidad_bruta_anual', 'ROI', 'tiempo_recuperacion'
96 ]
97
98 # Asegurarse de que todas las columnas existan
99 columnas_disponibles = [col for col in columnas_finales if col in df_resultado.columns]
100 df_final = df_resultado[columnas_disponibles]
101
102 # Muestreo de datos para verificación
103 print("Muestra del DataFrame final:")
104 print(df_final.head())
105
106 # Salida
107 output_table_1 = df_final

```

Ilustración 76 - Script para obtener las medidas restantes

Anexo C. Ejemplos de medidas DAX implementadas en Power BI:

```

1 Top5VentaBarMasBaratos =
2 VAR TopBarrio =
3     TOPN(
4         5,
5         ADDCOLUMNS(
6             FILTER(
7                 VALUES('insights_madrid_v1 dim_barrio'[nombre_barrio]),
8                 [PrecioMedioVenta] <> 0
9             ),
10            "PrecioBarrio", [PrecioMedioVenta]
11        ),
12        [PrecioBarrio], ASC
13    )
14 RETURN
15     CONCATENATEX(
16         TopBarrio,
17         'insights_madrid_v1 dim_barrio'[nombre_barrio],
18         UNICHAR(10),
19         [PrecioMedioVenta],
20         ASC
21     )
22

```

Ilustración 77 - Medida Dax_Top5VentaBarriosMasBaratos

```

1 Top5VentaDisMasCaros =
2 VAR TopDistritos =
3     TOPN(
4         5,
5         ADDCOLUMNS(
6             VALUES('insights_madrid_v1 dim_distrito'[nombre_distrito]),
7             "PrecioDistrito", [PrecioMedioVenta]
8         ),
9         [PrecioDistrito], DESC
10    )
11 RETURN
12     CONCATENATEX(
13         TopDistritos,
14         'insights_madrid_v1 dim_distrito'[nombre_distrito],
15         UNICHAR(10),
16         [PrecioMedioVenta],
17         DESC
18     )
19
20

```

Ilustración 78 - Medida Dax_Top5VentaDistritosMasCaros

```

1 RentabilidadBruta =
2 DIVIDE(
3     [PrecioMedioAlquiler] * 12,
4     [PrecioMedioVenta],
5     0
6 )
7

```

Ilustración 79 - Medida Dax_RentabilidadBruta

```

1 PrecioMedioVenta =
2 CALCULATE(
3     AVERAGE('insights_madrid_v1 fact_operacion'[precio_m2]),
4     'insights_madrid_v1 fact_operacion'[tipo_operacion] = "venta"
5 )

```

Ilustración 80 - Medida Dax_PrecioMedioVenta

```

1 VolatilidadPrecio_m2 =
2 VAR TablaMeses =
3     CALCULATETABLE(
4         VALUES('insights_madrid_v1 dim_tiempo'[mes]),
5         ALLSELECTED('insights_madrid_v1 dim_tiempo'),
6         ALLEXCEPT(
7             'insights_madrid_v1 fact_operacion',
8             'insights_madrid_v1 dim_distrito'[id_distrito]
9         )
10    )
11 RETURN
12     STDEVX.P(
13         TablaMeses,
14         CALCULATE(
15             AVERAGE('insights_madrid_v1 fact_operacion'[precio_m2])
16         )
17     )
18

```

Ilustración 81 - Medida Dax_VolatilidadDelPrecioPorM2